Fatec
Barueri
Padre Danilo
José de Oliveira Ohl

TRABALHO DE GRADUAÇÃO

APLICAÇÃO DE MODELOS DE MACHINE LEARN PARA MELHORIA DA GESTÃO DE ESTOQUE, PREVISÃO DE DEMANDA E REDUÇÃO DO DESPERDÍCIO EM PEQUENOS RESTAURANTES

CAIO BANDEIRA DE FRANÇA
EDUARDO RIBEIRO PIMENTA
HEBERT ROCHA LIMA DA SILVA
ITALO SAMPAIO DE LUCENA

ORIENTADOR: PROF. VANDER RIBEIRO ELME

O SETOR DE RESTAURANTES NO BRASIL

49,4%

Taxa de criação de novos negócios em 2025

428 mil+

Estabelecimentos ativos até fevereiro/2026

ME / MEI

Maior parte do setor é de microempresas

Fonte: Observatório Setorial Territorial do Sebrae (2026), com base em dados da Receita Federal.

O SETOR DE RESTAURANTES NO BRASIL

Controle de estoque

Falta ou excesso de insumos, capital imobilizado e risco de perdas em perecíveis

Alta concorrência

Pressão por preço, qualidade e diferenciação no mercado local

Qualidade constante

Manter padrão de preparo e atendimento com equipes reduzidas

Logística e fluxo de caixa

Compras, reposição e equilíbrio financeiro no dia a dia

Fonte: Viana (2024).

MACHINE LEARNING COMO OPORTUNIDADE

O Machine Learning (ML) é uma área da Inteligência Artificial que utiliza algoritmos para analisar dados, identificar padrões e realizar previsões com base em informações históricas.

DISSO SURGE A QUESTÃO DE PESQUISA:

“Em que medida modelos de Machine Learning podem contribuir para a previsão da demanda e para a melhoria da gestão de estoque em restaurantes de pequeno porte?”

OBJETIVO GERAL

Propor e avaliar a aplicação de modelos preditivos baseados em algoritmos de Machine Learning como ferramenta de suporte à decisão na previsão de demanda e na gestão de estoque, a fim de apoiar restaurantes de pequeno porte.

OBJETIVOS ESPECÍFICOS

01

Identificar e examinar os conceitos fundamentais de **administração de estoques**, **previsão de demanda** e **Machine Learning**

02

Mapear, por **pesquisa de campo**, os requisitos e desafios de coleta de dados e fatores operacionais em pequenos restaurantes

03

Desenvolver e treinar modelos de ML (Ensemble Ponderado, Ensemble Simples, Random Forest, LightGBM, Ridge) em ambiente simulado

04

Analisar o desempenho dos modelos com métricas de precisão e examinar os resultados alcançados

JUSTIFICATIVA

ALTA MORTALIDADE DE PEQUENOS NEGÓCIOS

52,3%

dos pequenos negócios encerram em 5 anos

~59%

taxa de não sobrevivência entre os MEI

Perfis distintos de abertura

40% dos MEI abrem o negócio por necessidade.
50,9% das MPE surgem ao identificar uma oportunidade de mercado.
Isso reflete perfis diferentes de resiliência e planejamento empresarial.

Fonte: SEBRAE, 2025.

JUSTIFICATIVA

GARGALO OPERACIONAL E RELEVÂNCIA SOCIAL

Gestão de estoques como gargalo

A ausência de controle adequado contribui para aumento de custos, desperdício ou falta de insumos e redução de competitividade, levando a clientes insatisfeitos. Em restaurantes, o problema é agravado pela perecibilidade dos produtos.

721 mil+

postos de trabalho formais no ramo de Restaurantes e similares — principal empregador entre as micro e pequenas empresas no Brasil, liderando a geração de empregos em 13 estados e no DF.

Fonte: SEBRAE, 2025.

REFERENCIAL TEÓRICO

Oito blocos sustentam o protótipo, da gestão de estoques à previsão de demanda.

01
Gestão de estoques

02
Pequenos restaurantes

03
Ficha técnica de preparação

04
Desperdício de alimentos

05
IA e sistemas de apoio à decisão

06
Machine Learning

07
Algoritmos utilizados

08
Previsão de demanda

GESTÃO DE ESTOQUES

O estoque existe porque o ritmo de fornecimento e o da demanda raramente coincidem.

01
Quanto pedir
Tamanho do pedido de reposição.

02
Quando pedir
Momento certo de emitir o pedido.

03
Quanto manter
Estoque de segurança contra a incerteza da demanda e do fornecimento.

Equilíbrio entre três custos: manter estoque, fazer pedidos e faltar produto.

Slack, Brandon-Jones e Johnston (2018); Chopra e Meindl (2016); Ballou (2006).

CADA ITEM, UMA POLÍTICA

Um único parâmetro de reposição para todo o estoque tende a gerar distorções (Wanke, 2012).

REVISÃO CONTÍNUA
O pedido é emitido quando o nível de estoque atinge o ponto de reposição.

REVISÃO PERIÓDICA
O nível é verificado em intervalos fixos, e a reposição é feita a cada revisão.

Wanke (2012): quadro conceitual, com enfoque em itens de baixo consumo, que liga o comportamento da demanda de cada item à escolha da política de estoque.

Silver, Pyke e Thomas (2016). Magalhães et al. (2022) aplicaram a classificação ABC e as duas revisões em um restaurante.

ESTOQUE EM PEQUENOS RESTAURANTES

Perecibilidade
Insumos de vida útil curta não podem ser comprados só por desconto ou disponibilidade.

Equipe enxuta
Poucas pessoas acumulam compra, recebimento e preparo, então os controles precisam ser simples.

Demanda por prato
Cada prato consome insumos em proporções diferentes, e a demanda é variável.

Insumos compartilhados
A demanda de um insumo soma as vendas de vários pratos, aspecto pouco explorado na literatura.

Moreira et al. (2025): controles predominantemente manuais. Magalhães et al. (2022). Bergsma, de Ruijt e Bhulai (2025).

FICHA TÉCNICA DE PREPARAÇÃO

Vendas previstas por prato → **Ficha técnica: insumo × quantidade por porção** → **Necessidade de insumos**

O QUE A FICHA REGISTRA

- Ingredientes e quantidades por pessoa
- Peso bruto e peso líquido
- Custo da preparação e da porção
- Número de porções e rendimento

FC = PB ÷ PL

Fator de correção: expressa as perdas do pré-preparo.

Akutsu et al. (2005); Cabral, Morais e Carvalho (2013). PB = peso bruto; PL = peso líquido.

DESPERDÍCIO DE ALIMENTOS

1,05 bi t
de alimentos desperdiçados em 2022 no varejo, nos serviços de alimentação e nos domicílios.

28%
do total veio dos serviços de alimentação, cerca de 290 milhões de toneladas.

8% a 10%
das emissões globais de gases de efeito estufa estão associadas a perdas e desperdício de alimentos.

Prever a demanda reduz o desperdício por excesso de compra ou produção, mas não elimina erros de preparo nem porções mal dimensionadas.

UNEP (2024); FAO (2024); Maganha et al. (2025); Kaman et al. (2024).

INTELIGÊNCIA ARTIFICIAL E ML

INTELIGÊNCIA ARTIFICIAL
Sistemas que inferem como gerar previsões, recomendações ou decisões a partir de objetivos.

MACHINE LEARNING
Aprende padrões direto de dados históricos.

Aprendizado supervisionado: regressão para prever a demanda

TRÊS CAMINHOS DO ML NO ESTOQUE

01 Estimar a demanda antes da otimização

02 Incorporar o ML aos modelos de otimização

03 Aprendizado por reforço para definir políticas de estoque

OECD (2022; 2024); Géron (2022); Bergsma, de Ruijt e Bhulai (2025).

SISTEMAS DE APOIO À DECISÃO

Sistema interativo que ajuda o gestor a usar dados e modelos, sem substituí-lo (Sprague, 1980).

BASE DE DADOS
Histórico de vendas e ficha técnica dos pratos.

BASE DE MODELOS
Modelo de previsão de demanda (Machine Learning).

INTERFACE
Painel em Streamlit com as sugestões de compra.

A decisão de compra continua com o gestor. Envolvê-lo na escolha das variáveis ajudou a ganhar confiança nas previsões (Groene e Zakharov, 2024).

Power (2002) classifica os SAD; o protótipo se aproxima do tipo orientado a modelos.

ALGORITMOS UTILIZADOS

01 Média móvel
Média dos 7 dias anteriores; referência mínima.

02 Ridge
Regressão linear com penalização L2, estável com variáveis correlacionadas.

03 Random Forest
Média de várias árvores de decisão; capta não linearidades.

04 LightGBM
Árvores em sequência, cada uma corrige os erros das anteriores.

05 Ensemble simples
Média aritmética dos três modelos; reduz a variância.

06 Ensemble ponderado
Pesos pelo inverso do erro (WAPE); mais peso a quem erra menos.

Hyndman e Athanasopoulos (2021); Hoerl e Kennard (1970); Breiman (2001); Ke et al. (2017); Dietterich (2000); Bates e Granger (1969).

VALIDAÇÃO EM SÉRIES TEMPORAIS

Avaliar o modelo em dados que ele não viu evita o sobreajuste (Géron, 2022).

TREINO: o passado

VALIDAÇÃO: período posterior

tempo →

POR QUE NÃO SORTEAR?
Misturaria dias anteriores e posteriores ao previsto, e as métricas ficariam otimistas.

SEM VAZAMENTO DE INFORMAÇÃO
Defasagens e médias móveis usam apenas dias anteriores ao dia previsto.

Hyndman e Athanasopoulos (2021).

PREVISÃO DE DEMANDA

Prever é estimar a procura futura com dados históricos, e não eliminar a incerteza (Ackermann e Sellitto, 2022).

Groene e Zakharov (2024)
Gradient boosting com clima, feriados e eventos reduziu o RMSE em 22% a 33% frente às previsões manuais dos gestores.

Chae, Sheu e Park (2024)
Entre modelos tradicionais, de ML e de deep learning, o melhor varia com o período e os dados.

Posch et al. (2022)
Vendas diárias de pratos têm múltiplas sazonalidades e valores atípicos.

Kim (2025)
Rede neural modela centenas de itens de cardápio, com dados meteorológicos.

MÉTRICAS

MAE

O Erro Absoluto Médio calcula a média das diferenças absolutas entre os valores

RMSE

O Erro Quadrático Médio calcula a média dos quadrados das diferenças entre os valores s

MAPE

O Erro Percentual Absoluto Médio expressa o tamanho do erro em formato percentual em relação aos valores reais

WAPE

O Erro Percentual Absoluto Ponderado calcula a média dos erros percentuais de cada item isoladamente

Viés

O Viés indica a tendência sistemática de subestimar ou superestimar a demanda

DO REFERENCIAL AO TRABALHO

01
Estoque por item
Cada insumo pede uma política própria, e a previsão de demanda alimenta a reposição.

02
Lacuna na literatura
Ligar a previsão por prato à ficha técnica para chegar aos insumos é pouco explorado (Bergsma et al., 2025).

03
Escolha dos modelos
Da média móvel ao ensemble, comparados com validação temporal para medir o ganho sobre a referência.

O gestor segue no centro da decisão: o sistema apoia, não substitui.

CLASSIFICAÇÃO DA PESQUISA

Abordagem

Quali-quantitativa, porque o formulário investiga a necessidade e gera dados estatísticos sobre as dores.

Objetivos

Informações de rotina coletadas em pesquisas exploratórias em restaurantes locais (observações e questionários simples).

Natureza

Aplicada, pois propõe um artefato tecnológico como resposta prática.

DESIGN SCIENCE RESEARCH (DSR)

Metodo voltado à solução de problemas específicos, que projeta um artefato. Busca uma solução satisfatória, não necessariamente ótima. A escolha foi feita a partir do avanço do diagnóstico para a projeção do artefato.

ETAPA 1 - **Conscientização:** Formulário aplicado a nove gestores.

ETAPA 2 - Concepção Requisitos e protótipo em Python com Streamlit

ETAPA 3 - Demonstração Protótipo exibido com dados fictícios

ETAPA 4 - Avaliação Métricas MAE, RMSE, MAPE, WAPE e Bias

DELIMITAÇÃO DA PESQUISA

Nove Restaurantes de pequeno porte independentes, sem rede ou franquia, na Zona Oeste de São Paulo. Com foco exploratório, sem pretensão de generalizar.

Participantes
Gestores, proprietários ou responsáveis, escolhidos de forma intencional por decidir sobre compras, reposição e planejamento.

Escopo Tecnológico
Protótipo com simulação de estoque, demanda e registros de desperdícios. Inicialmente sem integração.

INSTRUMENTO E COLETA DE DADOS

Instrumento - Google Forms

Perguntas abertas, múltipla escolha escolha e escala de Likert de 1 a 5, e por fim, duas perguntas opcionais sobre as ferramentas utilizadas e mudanças tecnológicas.

Aplicação

Remota durante três meses, link enviado via WhatsApp e Facebook, com esclarecimento de dúvidas durante o preenchimento.

Objetivo - Dados Reais

Evidenciar que realmente há a necessidade de uma ferramenta para o estoque, previsão de demanda e desperdício.

DADOS DA PESQUISA

“Mais de 1 bilhão de refeições são desperdiçadas diariamente no mundo”

(UNEP, 2024)

“A inteligência artificial interpreta dados e aprende com experiências para executar atividades preditivas de forma autônoma”

(Russell e Norvig, 2021)

“Soluções de IA podem auxiliar no controle de desperdícios e planejamento de estoque, tornando as operações mais eficientes e sustentáveis”

(Cejas, 2025; Vukolić et al., 2025)

PERFIL DA AMOSTRA

O diagnóstico parte de nove restaurantes

Estabelecimentos independentes da Zona Oeste de São Paulo, com diferentes formatos e tamanhos de equipe.

7

restaurantes próprios e independentes

1

dark kitchen

1

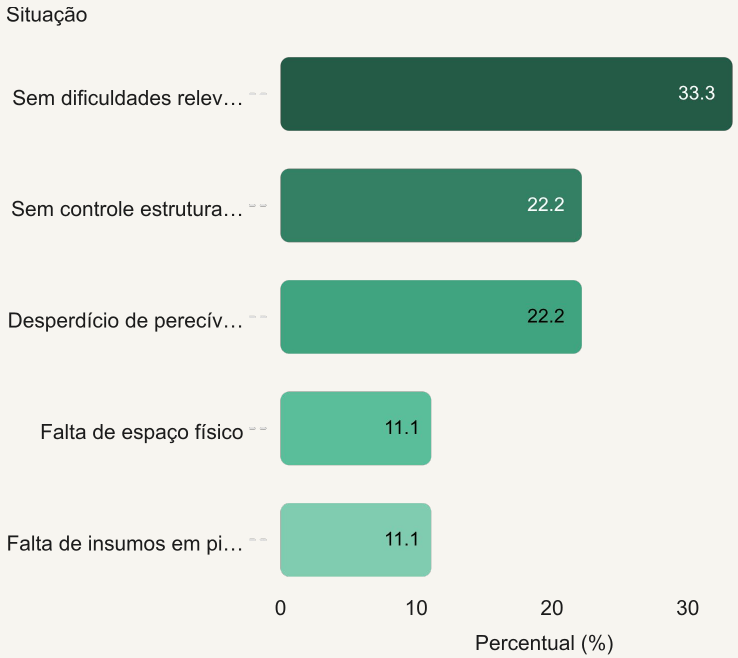
próprio com delivery

5 operações têm até 5 funcionários; 2 têm mais de 30.



O controle de estoque ainda é desigual

As respostas distribuem-se entre ausência de dificuldades relevantes e problemas específicos de controle, espaço, perdas e reposição.

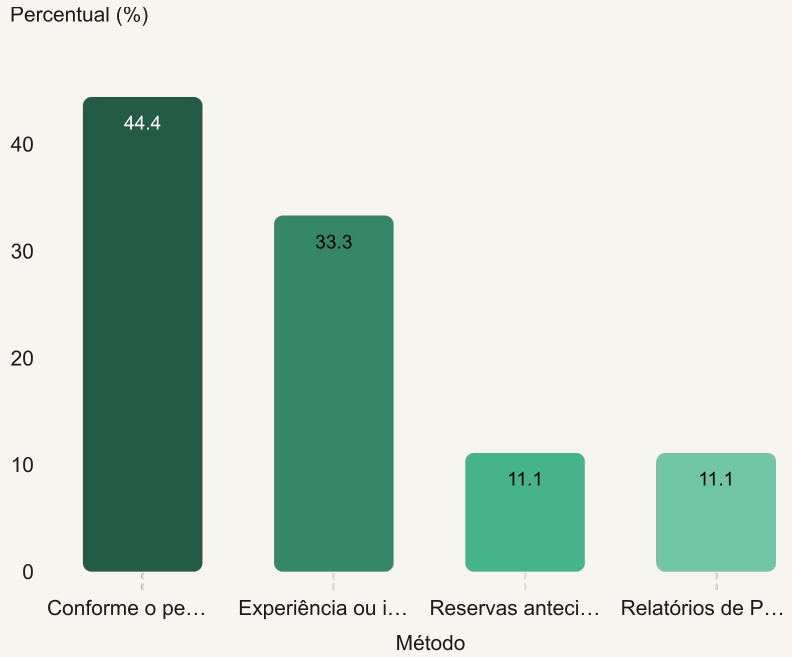


O diagnóstico aponta para centralização de entradas e saídas, níveis de estoque e alertas de reposição.

DEMANDA

88,9% ainda estimam a demanda sem método estruturado

Produção conforme o pedido, experiência do gestor e reservas antecipadas predominam sobre o uso sistemático de dados.



Há espaço para transformar histórico de vendas em apoio mais consistente às decisões de compra e produção.

VARIÁVEIS EXTERNAS

Fatores externos podem explicar parte da variação

Clima, eventos e feriados influenciam a operação, mas a intensidade percebida varia entre os restaurantes.

3,11
Média de influência em escala de 1 a 5

66,7%
notas entre 3 e 5

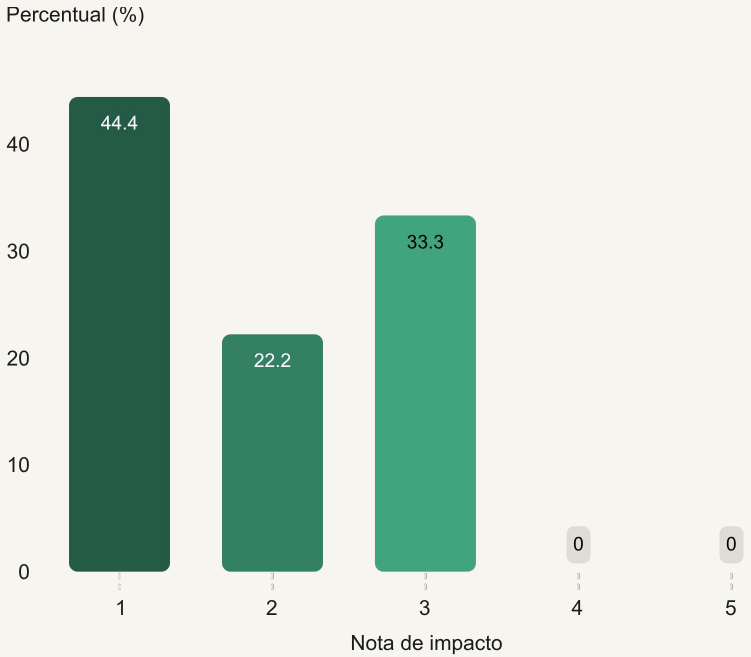
33,3%
deram nota 1

As variáveis externas merecem ser avaliadas no modelo, mas não devem ser tratadas como igualmente relevantes para todos os restaurantes.

DESPERDÍCIO

O desperdício é específico, não uniforme

A percepção geral do impacto é baixa, mas os perecíveis aparecem como desafio concreto de estoque.



Média do impacto percebido: 1,89 em uma escala de 1 a 5. Nenhum restaurante atribuiu nota 4 ou 5. Ainda assim, 22,2% apontaram perecíveis como principal desafio de estoque.

A maturidade tecnológica é heterogênea

As operações combinam diferentes níveis de análise financeira, ferramentas digitais e integração.

Margem

55,6% analisam regularmente a margem de lucro; **44,4%** têm apenas uma noção.

Ferramentas

Excel, Rodo digital, redes sociais, Linx Menew e Cloudfy.

Lacunas

1 participante não possui ferramenta de tecnologia para gestão.

Demanda

Sistemas integrados e conexão com plataformas de delivery.

CRESCIMENTO

O crescimento pressiona pessoas e processos

Se o movimento dobrasse, a maior pressão percebida estaria na equipe e na escala.

33,3%
equipe e escala

22,2%
pedidos da cozinha ou delivery

11,1%
pedidos, financeiro e fechamento de caixa

33,3%
não souberam indicar ou afirmaram que a situação não ocorre

A expansão da demanda exige visibilidade operacional antes de ampliar compras e produção.

Do diagnóstico emergem quatro necessidades

01

Prever a demanda

Reduzir a dependência de intuição e pedidos do dia.

02

Estruturar o estoque

Registrar entradas, saídas, níveis e perdas.

03

Acompanhar desperdícios

Priorizar perecíveis, consumo, validade e giro.

04

Integrar tecnologias

Aproveitar dados já existentes sem exigir uma operação complexa.

A proposta é um apoio à decisão: recomendações para o gestor, não substituição do julgamento humano.

CONCLUSÃO DA ANÁLISE

A principal lacuna está na previsão de demanda e na estruturação do controle de estoque.

1 de 9

estabelecimentos usa PDV/ERP para estimar a demanda.

A evidência é inicial

A solução orientada por dados não permite generalizar os resultados.

Amostra reduzida

Orienta prioridades de desenvolvimento e avaliação futura.

GERAÇÃO DOS DADOS

5 PRATOS

- Feijoada;
- Frango;
- Grelhado;
- Lasanha;
- Salada Caesar;
- Strogonoff.

365 DIAS

28/10/2025 a 27/10/2026
com 1.825 observações

10 INSUMOS

Ficha técnica com 21 relações
Ex.: Tomate, Arroz, Feijão…

Por que dados sintéticos?

Dados reais de vendas de restaurantes são, em geral, de propriedade dos estabelecimentos e pela falta de uma base de um negócio para testes, este estudo utiliza um conjunto sintético gerado por um script. O gerador reproduz padrões realistas: sazonalidade semanal e anual, clima, feriados, promoções, picos de demanda e rupturas. Semente aleatória fixa garante reprodutibilidade.

GERAÇÃO DOS DADOS

5 PRATOS

- Feijoada;
- Frango;
- Grelhado;
- Lasanha;
- Salada Caesar;
- Strogonoff.

365 DIAS

28/10/2025 a 27/10/2026
com 1.825 observações

10 INSUMOS

Ficha técnica com 21 relações
Ex.: Tomate, Arroz, Feijão…

Por que dados sintéticos?

Dados reais de vendas de restaurantes são, em geral, de propriedade dos estabelecimentos e pela falta de uma base de um negócio para testes, este estudo utiliza um conjunto sintético gerado por um script. O gerador reproduz padrões realistas: sazonalidade semanal e anual, clima, feriados, promoções, picos de demanda e rupturas. Semente aleatória fixa garante reprodutibilidade.

COMPONENTES DO PERFIL DE DEMANDA

Dia da semana	Multiplicadores por dia. Ex.: Feijoada +85% sáb / +75% dom; Salada −25% dom
Sazonalidade anual	Perfil mensal interpolado (fator 0,75). Feijoada +56% jul / −34% dez
Tendência	Taxa mensal + crescimento geral 0,4%. Strogonoff −0,8%; Frango +2,2%
Mudança de cardápio	Ajuste gradual a partir de 60% do período (~3 semanas). Strogonoff −15%
Calendário e clima	Feriados, pontes, dia de pagamento, datas comemorativas, temperatura e chuva
Promoções e eventos	Promoções 14–58%; picos 1,4–2,2×; rupturas 55–90% da demanda

COMPONENTES DO PERFIL DE DEMANDA

Prato	Demanda-base (un./dia)	Fim de semana (sáb. / dom.)	Sazonalidade (jul. / dez.)	Tendência ao mês	Efeito do clima por °C	Efeito de promoção
Feijoada	40	+85% / +75%	+56% / −34%	−0,1%	−3,0%	+32% a +58%
Frango grelhado	45	+15% / +10%	0% / +8%	+2,2%	+1,0%	+18% a +33%
Lasanha	30	+55% / +50%	+15% / 0%	−0,4%	−1,5%	+28% a +52%
Salada caesar	20	−15% / −25%	−49% / +56%	+0,9%	+4,0%	+14% a +26%
Strogonoff	35	+35% / +30%	−11% / +15%	−0,8%	−0,5%	+21% a +39%

Fonte:elaborado pelo autor (2026), a partir do gerador de dados do projeto.

ENGENHARIA DE VARIÁVEIS

15 FEATURES

CALENDÁRIO

- dia_semana
- mes
- dia_ano
- fim_de_semana
- feriado

EXÓGENAS

- temperatura
- promocao

HISTÓRICAS

Variáveis de Atraso (*Lags*)

- lag_1
- lag_2
- lag_7
- lag_14

Médias Móveis (*Moving Averages*)

- mm_7
- mm_14
- mm_30

Desvio Padrão (Standard Deviation)

- std_7

Validação temporal: últimos 30 dias (28/09–27/10/2026) | Treino: 27/11/2025–27/09/2026

COMPARAÇÃO DOS MODELOS

Modelo	MAE	RMSE	MAPE (%)	WAPE (%)	Viés
LightGBM	7,19	9,96	18,23	16,90	−1,12
Ensemble ponderado	7,24	9,93	18,46	17,00	−1,33
Ensemble simples	7,25	9,95	18,49	17,03	−1,34
Ridge	7,59	10,32	19,54	17,83	−1,22
Random Forest	7,94	10,79	19,91	18,65	−1,67
Baseline (média móvel de 7 dias)	9,13	12,19	23,48	21,46	−0,43

Fonte:elaborada pelo autor (2026), a partir da saída do módulo de treinamento.

DESTAQUE

LightGBM reduziu WAPE de 21,46% → 16,90%

Melhora de ~21% em relação à baseline. Todos os modelos apresentam viés negativo leve.

DESEMPENHO POR PRATO (LightGBM)

Prato	MAE	WAPE (%)	Viés	Venda média diária
Feijoada	6,55	13,64	+0,36	48,0
Frango grelhado	10,48	15,17	−4,01	69,1
Lasanha	7,76	22,46	−0,48	34,5
Salada caesar	5,25	18,64	−2,35	28,2
Strogonoff	5,93	17,96	+0,87	33,0

Fonte:elaborada pelo autor (2026), a partir da saída do módulo de treinamento com previsão de um passo (dia)

OBSERVAÇÕES

- O frango grelhado apresenta o viés negativo mais acentuado
- A lasanha apresenta o maior WAPE (22,46%), apesar de viés pequeno, o que indica erros de dispersão e não de direção

PREVISÃO RECURSIVA (30 DIAS)

O modelo prevê sem acesso às vendas reais — cada previsão alimenta a seguinte.

1-7 dias	8-14 dias	15-21 dias	22-28 dias	29-30 dias
14,83%	19,53%	24,90%	23,42%	24,35%

Conclusão operacional

O sistema deve ser usado para planejar compras de preferencia a curto prazo (7 dias). O WAPE da 1ª semana (14,83%) é o valor relevante para a decisão semanal. Erro total da recursiva: 20,99%.

PROTOTIPO

MÓDULO OPERACIONAL

FALTA

- Saldo negativo
- Sugestão: comprar
- diferença + 10%

EXCESSO

- Sobra > 50%
- do estoque atual

FALTA

- Dentro da faixa
- aceitável

EX.: **Necessidade de insumos em 7 dias e saldo, com estoques ilustrativos (com data de início em 28/10/2026)**

Insumo	Unid.	Estoque atual	Necessidade em 7 dias	Saldo	Sobra relativa	Classificação
Arroz	kg	180,00	92,16	87,84	48,8%	OK
Feijão	kg	90,00	42,60	47,40	52,7%	EXCESSO
Queijo	kg	20,00	31,43	−11,43	−57,2%	FALTA

Fonte: elaborada pelo autor (2026), a partir da comparação entre previsões e vendas.

VIDEO MODELO

VIABILIDADE EM PEQUENOS RESTAURANTES

STACK TECNOLÓGICA

- Python + scikit-learn
- LightGBM + Streamlit

- 100% open-source
- Roda em PC pessoal
- Sem GPU / sem nuvem

PRÉ-REQUISITOS

1. Vendas digitalizadas
2. Ficha técnica documentada
3. Registro de perdas

Sem os 2 primeiros pontos,
o modelo não tem o que aprender.

Custo vs. sistemas comerciais

Sistemas comerciais: R$ 49 a R$ 241/mês (licença recorrente)(CONNECT PLUG, 2026; SAIPOS, 2026). Solução proposta: sem licença recorrente — custo concentrado na implantação (ficha técnica, cadastro e treinamento). Custos de implantação ainda não quantificados neste estudo.

LIMITAÇÕES E TRABALHOS FUTUROS

LIMITAÇÕES

- Dados sintéticos — não comprovam desempenho real
- Mesma janela usada para seleção e avaliação (otimismo)
- Erro cresce após a 1ª semana (~24%)
- Apenas 1 ano de histórico

TRABALHOS FUTUROS

- Testar com dados reais de um restaurante
- Acompanhar operação e medir impacto financeiro
- Ampliar cardápio e horizonte histórico
- Risco de desperdício por insumo/dia

Validação temporal: últimos 30 dias (28/09–27/10/2026) | Treino: 27/11/2025–27/09/2026

CONSIDERAÇÕES FINAIS — PRINCIPAIS ACHADOS

Oportunidade clara

88,9% dos gestores na pesquisa não usam métodos preditivos estruturados e 22,2% citam desperdício de perecíveis como principal gargalo.

Resultados promissores

LightGBM: WAPE 16,90% (vs. 21,46% da baseline) — melhora de ~21%. 1ª semana recursiva: 14,83%.

Articulação previsão para decisão

O protótipo antecipa a necessidade de insumos e gera sugestões de compra, sem substituir o julgamento do gestor.

Acessibilidade e adaptabilidade

Stack open-source, sem licença recorrente e adaptável a outros cardápios — basta atualizar a ficha técnica.

PRÓXIMOS PASSOS

- **Testar o sistema com dados reais de um restaurante;**
- **reservar um período de teste desde o início;**
- **acompanhar a operação para medir o impacto.**

REFERÊNCIAS

SAIPOS. **Planos e preços: conheça os benefícios do Sistema Saipos**. Disponível em: https://saipos.com/planos-e-precos. Acesso em: 11 nov. 2026.

CONNECT PLUG. **Connect Plug**. Disponível em: https://www.cplug.com.br. Acesso em: 11 nov. 2026.

VIANA, Flavia De Siqueira. Por que ter um restaurante é um negócio tão desafiador? Comunidade Sebrae, 14 out. 2024.

SEBRAE. **Restaurantes e similares**: emprego e empresas. Observatório Setorial Territorial, 2026. Disponível em: https://observatorio.sebrae.com.br/profile/industry/restaurantes-e-similares. Acesso em: 9 jun. 2026.

SEBRAE. **Sobrevivência das empresas mercantis brasileiras (2020–2024)**: relatório técnico. Brasília: Sebrae, 28 fev. 2025. Disponível em: https://inteligencia.sebraemg.com.br. Acesso em: 9 jun. 2026.

SEBRAE. **Panorama do Emprego nas Micro e Pequenas Empresas**. Brasília: Sebrae, 2026. Disponível em: https://datasebrae.com.br/panorama-do-emprego/. Acesso em: 10 nov. 2026.

OBRIGADO PELA ATENÇÃO!

CAIO BANDEIRA DE FRANÇA
EDUARDO RIBEIRO PIMENTA
HEBERT ROCHA LIMA DA SILVA
ITALO SAMPAIO DE LUCENA

ORIENTADOR: PROF. VANDER RIBEIRO ELME