

4.1 Gestão de estoques

A gestão de estoques envolve o conjunto de decisões que buscam coordenar a demanda existente e a oferta de produtos ao longo do tempo, considerando as características de cada item, da operação e da própria demanda (WANKE, 2012). Três decisões centrais orientam esse processo: quando pedir, quanto pedir e quanto manter como estoque de segurança — respostas que dependem das circunstâncias de cada produto e não podem ser generalizadas para todo o estoque de uma organização.

O comportamento da demanda é uma das principais variáveis dessas decisões. Wanke (2012) demonstra que itens diferentes apresentam padrões de consumo e variabilidade distintos, de modo que um único parâmetro de reposição aplicado a todo o estoque tende a gerar distorções: itens de alto consumo exigem lógica diferente da aplicada a itens de baixo consumo. Essa constatação sustenta a necessidade de classificar os itens individualmente antes de definir políticas de estoque, e é a base conceitual adotada neste trabalho.

A gestão de estoques também depende do controle das movimentações — entradas, saídas e consumo — para que decisões de reposição sejam tomadas com base em informações confiáveis, sem o que a organização perde a capacidade de identificar quais itens exigem atenção e qual nível de estoque é compatível com sua demanda real (WANKE, 2012). Essa fundamentação orienta a discussão a seguir, voltada às particularidades da gestão de estoques em pequenos restaurantes.

4.2 Gestão de estoques em pequenos restaurantes

Em pequenos restaurantes, a gestão de estoques soma às decisões gerais de reposição a perecibilidade dos insumos, a limitação de pessoal e a variabilidade da demanda por prato. Controles precisam ser simples e adequados à quantidade reduzida de funcionários, que frequentemente acumulam funções de compra, recebimento e preparo. Moreira et al. (2025), ao investigarem as barreiras na gestão de estoques de um restaurante familiar, identificaram controles predominantemente manuais e destacaram a influência da demanda sazonal e da cultura organizacional sobre os mecanismos de controle utilizados.

A perecibilidade dos insumos é outro aspecto central: ingredientes com vida útil curta não podem ser adquiridos apenas com base em descontos ou disponibilidade, sob risco de deterioração antes do consumo. Magalhães et al. (2022), em estudo de caso em um restaurante, aplicaram a classificação ABC sobre grupos de produtos do cardápio e compararam políticas de revisão contínua e periódica para apoiar a definição do estoque de reserva, demonstrando a aplicabilidade de técnicas de gestão de estoques mesmo em operações de pequeno porte.

Nem todo item do estoque de um restaurante compartilha, porém, essa urgência relacionada à deterioração. Itens não perecíveis — como canudos, guardanapos, embalagens e demais materiais descartáveis — não se deterioram com o tempo, mas ainda assim exigem controle adequado: sua falta compromete o atendimento tanto quanto a falta de um ingrediente, e seu consumo tende a acompanhar o volume de vendas e a composição do cardápio da mesma forma que o dos alimentos propriamente ditos. Essa distinção entre itens perecíveis e não perecíveis é outra expressão prática do princípio de que cada item deve ser gerenciado conforme suas próprias características de consumo, e não segundo uma política única aplicada a todo o estoque (WANKE, 2012).

A demanda de um restaurante, porém, não pode ser tratada como uma grandeza única: cada prato consome insumos em proporções diferentes, e um mesmo insumo costuma ser compartilhado entre vários pratos. Um item que compõe seis pratos diferentes tende a ter uma demanda agregada mais estável e previsível do que outro utilizado em apenas três receitas, cuja demanda soma variações menos correlacionadas entre si. Essa interdependência — em que a demanda de um insumo resulta da soma das vendas de vários itens do cardápio, e não da venda de um único produto — é reconhecida na literatura sobre controle de estoques como um dos aspectos que aumentam a complexidade de sistemas com múltiplos itens relacionados, ainda pouco explorado em aplicações práticas (BERGSMA; DE RUIJT; BHULAI, 2025). Essa característica reforça que a previsão de demanda de um pequeno restaurante não pode ser conduzida item a item de forma isolada, sendo necessário considerar como os insumos se relacionam por meio das fichas técnicas dos pratos.

Essas particularidades — a coexistência de itens perecíveis e não perecíveis, a limitação de estrutura e os insumos compartilhados entre pratos — tornam a

gestão de estoques em restaurantes especialmente sensível ao problema do desperdício de alimentos, discutido a seguir.

4.3 Desperdício de alimentos

O desperdício de alimentos refere-se à redução na quantidade ou qualidade dos alimentos decorrente de decisões tomadas por varejistas, serviços de alimentação e consumidores, distinguindo-se das perdas ocorridas em etapas anteriores da cadeia produtiva (FAO, 2024). Segundo o Food Waste Index Report 2024, aproximadamente 1,05 bilhão de toneladas de alimentos foram desperdiçadas em 2022 nos níveis de varejo, serviços de alimentação e domicílios — cerca de 19% dos alimentos disponíveis aos consumidores nesses segmentos —, dos quais aproximadamente 290 milhões de toneladas (28%) foram atribuídas ao setor de serviços de alimentação (UNEP, 2024). Além do impacto econômico direto, a FAO estima que perdas e desperdício de alimentos estejam associados a cerca de 8% a 10% das emissões globais de gases de efeito estufa (FAO, 2024).

No ambiente de restaurantes, o desperdício pode ocorrer em diferentes momentos: durante o preparo, em pratos não servidos, em sobras deixadas pelos consumidores e em alimentos não vendidos. Maganha et al. (2025), em estudo de caso em um restaurante japonês, identificaram essas quatro situações e relacionaram o excesso de estoque a previsões inadequadas de demanda e vendas, apontando a previsão imprecisa como a causa mais provável do desperdício observado no estabelecimento. A revisão sistemática de Kaman et al. (2024) reforça que o desperdício em restaurantes tem natureza multifatorial, envolvendo tanto aspectos operacionais quanto comportamentais dos consumidores.

Essa multiplicidade de causas indica que a previsão de demanda pode contribuir para reduzir formas específicas de desperdício associadas ao excesso de produção ou de compra, mas não elimina outras causas, como erros de preparo ou porções mal dimensionadas (MAGANHA et al., 2025; KAMAN et al., 2024). Essa ressalva orienta a forma como a Inteligência Artificial é tratada neste trabalho: como recurso de apoio a um problema específico, e não como solução geral para o desperdício.

4.4 Inteligência Artificial

A Inteligência Artificial (IA) é definida pela OECD (2024) como um sistema baseado em máquina que, a partir de objetivos explícitos ou implícitos, utiliza informações recebidas para inferir como produzir previsões, conteúdos, recomendações ou decisões capazes de influenciar ambientes físicos ou virtuais, podendo apresentar diferentes níveis de autonomia e adaptação após sua implantação. Essa definição situa a IA como um campo amplo de métodos orientados à produção de resultados a partir de dados e objetivos previamente estabelecidos, e não apenas como automação de tarefas.

Dentro desse campo, o Machine Learning (ML) corresponde a um subconjunto de técnicas baseadas em métodos estatísticos, voltado à identificação de padrões diretamente a partir de dados históricos (OECD, 2022). Essa distinção é relevante para este trabalho: a IA é o conceito abrangente que fundamenta a utilização de sistemas de apoio à decisão, enquanto o ML é a técnica específica utilizada para transformar dados operacionais em previsões.

Em pequenos negócios, a adoção de IA envolve limitações relacionadas à disponibilidade de dados, recursos financeiros e conhecimento técnico, de modo que sua utilização deve estar associada a uma necessidade operacional concreta e a resultados compreensíveis pelos responsáveis pelo processo. Sistemas de IA devem ainda considerar aspectos de confiabilidade, transparência e gerenciamento de vieses (TABASSI, 2023), já que uma previsão incorreta pode influenciar diretamente uma decisão de compra e resultar em excesso de estoque ou falta de produtos. A revisão de Bergsma, de Ruijt e Bhulai (2025), que analisou 122 estudos sobre ML aplicado ao controle de estoques, identifica a previsão de demanda como uma das principais formas de integração entre ML e gestão de estoques, ao lado de desafios ainda existentes quanto à aplicação em situações reais.

4.5 Machine Learning

O Machine Learning constitui uma área da IA voltada ao desenvolvimento de sistemas capazes de aprender padrões a partir de dados de treinamento, em vez de depender exclusivamente de regras definidas manualmente (GÉRON, 2022). O processo típico envolve a preparação dos dados, o treinamento do modelo, sua avaliação com dados não utilizados no treinamento e, por fim, sua utilização para

produzir previsões — etapa em que a qualidade e a representatividade dos dados são tão determinantes quanto a técnica escolhida (GÉRON, 2022).

Entre as principais formas de aprendizado estão o supervisionado, o não supervisionado e o por reforço. No aprendizado supervisionado — o mais relevante para problemas de previsão —, o algoritmo aprende a relação entre variáveis de entrada e um resultado conhecido, podendo estimar categorias (classificação) ou valores numéricos (regressão), como a quantidade futura de demanda a partir de dados históricos de vendas (OECD, 2022). Um dos principais riscos nesse processo é o *overfitting*, quando o modelo se ajusta excessivamente aos dados de treinamento e perde capacidade de generalizar para novas situações (GÉRON, 2022).

Bergsma, de Ruijt e Bhulai (2025) identificam três formas de integrar ML ao controle de estoques: utilizá-lo para gerar estimativas de demanda antes da otimização; incorporá-lo diretamente aos modelos de otimização; ou empregá-lo, por meio de aprendizado por reforço, para definir políticas de estoque de forma dinâmica. Os autores também apontam que sistemas com múltiplos itens relacionados entre si — como ocorre quando vários produtos finais compartilham os mesmos insumos — ainda representam uma lacuna pouco explorada pelas aplicações práticas de ML em estoques, o que reforça a relevância de investigar esse aspecto no contexto de restaurantes, discutido na seção seguinte.

4.6 Previsão de demanda

A previsão de demanda consiste em estimar o comportamento futuro da procura por produtos a partir de dados históricos, com o objetivo de apoiar decisões de planejamento, e não de eliminar a incerteza sobre a demanda futura (ACKERMANN; SELLITTO, 2022). Entre os métodos disponíveis estão abordagens qualitativas, baseadas em julgamento de especialistas, e quantitativas, que utilizam séries temporais para identificar componentes como tendência e sazonalidade e projetá-los para períodos futuros (ACKERMANN; SELLITTO, 2022).

A qualidade de uma previsão é avaliada comparando valores previstos e observados por meio de métricas como o erro absoluto médio (MAE), a raiz do erro quadrático médio (RMSE) e o erro percentual absoluto médio (MAPE), cada uma mais adequada a determinados contextos de dados e de custo do erro

(ACKERMANN; SELLITTO, 2022). Em restaurantes, essa escolha tem implicações práticas: um erro que leva à superestimação da demanda de um insumo perecível tende a ser mais custoso do que o mesmo erro aplicado a um item não perecível.

Estudos recentes aplicam Machine Learning à previsão de vendas em restaurantes com resultados relevantes. Schmidt, Kabir e Hoque (2022) avaliaram diferentes modelos de ML para prever vendas em um restaurante de médio porte, destacando a importância da seleção de variáveis relacionadas a tendência e sazonalidade. Posch et al. (2022) desenvolveram modelos para prever vendas diárias de itens de cardápio a partir de dados de ponto de venda, identificando múltiplas sazonalidades e valores atípicos como características típicas desse tipo de série. Chae, Sheu e Park (2024) compararam modelos tradicionais, de ML e de Deep Learning em uma rede de restaurantes, constatando que o desempenho relativo entre eles varia conforme o período e as características dos dados analisados. Mais recentemente, Kim (2025) desenvolveu um sistema baseado em redes neurais para modelar individualmente centenas de itens de cardápio, incorporando dados meteorológicos além do histórico de vendas.

Esse nível de detalhamento por item é especialmente relevante para o problema investigado neste trabalho: como os insumos de um restaurante costumam ser compartilhados entre vários pratos, a demanda de cada ingrediente resulta da combinação das vendas de diferentes itens do cardápio, e não de um único produto. Modelar a demanda apenas no nível do prato, sem considerar essa relação entre receitas e insumos, tende a subestimar a complexidade real do problema de estoque em pequenos restaurantes — uma lacuna que a literatura sobre ML em controle de estoques ainda identifica como pouco explorada (BERGSMA; DE RUIJT; BHULAI, 2025).

Dessa forma, a previsão de demanda constitui uma etapa intermediária entre os dados históricos e as decisões de estoque: os dados descrevem o comportamento passado, o modelo produz uma estimativa e essa estimativa, considerada dentro de sua margem de erro, apoia — sem substituir — a avaliação do responsável pela gestão do restaurante.

REFERÊNCIAS

ACKERMANN, Andres E. F.; SELLITTO, Miguel A. Métodos de previsão de demanda: uma revisão da literatura. *Innovar*, v. 32, n. 85, p. 83-99, 2022. DOI: <https://doi.org/10.15446/innovar.v32n85.100979>. Acesso em: 28 set. 2026.

BERGSMA, Ritsaart; DE RUIJT, Corné; BHULAI, Sandjai. A systematic review of machine learning approaches in inventory control optimization. *Operations Research Perspectives*, v. 15, 100367, 2025. DOI: <https://doi.org/10.1016/j.orp.2025.100367>. Acesso em: 28 set. 2026.

CHAE, Bongsug (Kevin); SHEU, Chwen; PARK, Eunhye Olivia. The value of data, machine learning, and deep learning in restaurant demand forecasting: insights and lessons learned from a large restaurant chain. *Decision Support Systems*, v. 184, 114291, 2024. DOI: <https://doi.org/10.1016/j.dss.2024.114291>. Acesso em: 14 set. 2026.

FAO. Food loss and food waste. Rome: Food and Agriculture Organization of the United Nations, 2024. Disponível em: <https://www.fao.org/policy-support/policy-themes/food-loss-and-food-waste/en>. Acesso em: 13 set. 2026.

GÉRON, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow. 3. ed. Sebastopol: O'Reilly Media, 2022.

KAMAN, Gizem Sultan et al. The strategy food waste in restaurants: a systematic literature review. *Trends in Food Science & Technology*, v. 151, 104625, 2024. DOI: <https://doi.org/10.1016/j.tifs.2024.104625>. Acesso em: 16 set. 2026.

KIM, Sangoh. Development of an AI-based restaurant menu demand prediction model utilizing sales and meteorological data. *Food Science and Biotechnology*, v. 34, n. 15, p. 3597-3606, 2025. DOI: <https://doi.org/10.1007/s10068-025-01956-2>. Acesso em: 28 set. 2026.

MAGALHÃES, Mariana Carrilho et al. Aplicação de técnicas de gestão de estoques em uma pequena empresa: o caso de um restaurante. *Zeiki - Revista Interdisciplinar da Unemat Barra do Bugres*, 2022. Disponível em: <https://periodicos.unemat.br/index.php/zeiki/article/view/6154>. Acesso em: 16 set. 2026.

MAGANHA, Isabela et al. Unveiling food waste: a case study of a restaurant specializing in Japanese cuisine in Brazil. *Waste Management Bulletin*, v. 3, n. 4, 100261, 2025. DOI: <https://doi.org/10.1016/j.wmb.2025.100261>. Acesso em: 12 set. 2026.

MOREIRA, Vicente et al. Avaliação das barreiras na gestão de estoques do Restaurante Iguarias Cozinha do Mar utilizando o método DEMATEL. *Revista ADMPG*, v. 14, n. 2, 2025. DOI: <https://doi.org/10.5212/Admpg.v.01.2503.016>. Acesso em: 12 set. 2026.

OECD. OECD Framework for the Classification of AI Systems. Paris: OECD Publishing, 2022. DOI: <https://doi.org/10.1787/cb6d9eca-en>. Acesso em: 16 set. 2026.

OECD. Explanatory memorandum on the updated OECD definition of an AI system. Paris: OECD Publishing, 2024. DOI: <https://doi.org/10.1787/623da898-en>. Acesso em: 16 set. 2026.

POSCH, Konstantin et al. A Bayesian approach for predicting food and beverage sales in staff canteens and restaurants. *International Journal of Forecasting*, v. 38, n. 1, p. 321-338, 2022. DOI: <https://doi.org/10.1016/j.ijforecast.2021.06.001>. Acesso em: 11 set. 2026.

SCHMIDT, Austin; KABIR, Md Wasi Ul; HOQUE, Md Tamjidul. Machine Learning Based Restaurant Sales Forecasting. *Machine Learning and Knowledge Extraction*, v. 4, n. 1, p. 105-130, 2022. DOI: <https://doi.org/10.3390/make4010006>. Acesso em: 11 set. 2026.

TABASSI, Elham. Artificial intelligence risk management framework (AI RMF 1.0). Gaithersburg: National Institute of Standards and Technology, 2023. DOI: <https://doi.org/10.6028/NIST.AI.100-1>. Acesso em: 12 set. 2026.

UNEP. Food waste index report 2024. Nairobi: United Nations Environment Programme, 2024.

WANKE, Peter. Quadro conceitual para gestão de estoques: enfoque nos itens de baixo consumo. *Gestão & Produção*, São Carlos, v. 19, n. 4, p. 677-687, 2012. DOI: <https://doi.org/10.1590/S0104-530X2012000400002>. Acesso em: 12 set. 2026.