FACULDADE DE TECNOLOGIA PADRE DANILO DE OLIVEIRA OHL

CAIO BANDEIRA DE FRANÇA
EDUARDO RIBEIRO PIMENTA
HEBERT ROCHA LIMA DA SILVA
ITALO SAMPAIO DE LUCENA

APLICAÇÃO DE MODELOS DE MACHINE LEARN PARA MELHORIA DA GESTÃO DE ESTOQUE, PREVISÃO DE DEMANDA E REDUÇÃO DO DESPERDÍCIO EM PEQUENOS RESTAURANTES

BARUERI

2026

FACULDADE DE TECNOLOGIA PADRE DANILO DE OLIVEIRA OHL

CAIO BANDEIRA DE FRANÇA
EDUARDO RIBEIRO PIMENTA
HEBERT ROCHA LIMA DA SILVA
ITALO SAMPAIO DE LUCENA

APLICAÇÃO DE MODELOS DE MACHINE LEARN PARA MELHORIA DA GESTÃO DE ESTOQUE, PREVISÃO DE DEMANDA E REDUÇÃO DO DESPERDÍCIO EM PEQUENOS RESTAURANTES

Relato tecnológico apresentado à banca examinadora da Faculdade de Tecnologia de Barueri como requisito final para obtenção do título de tecnólogo em gestão da tecnologia da informação.
Orientador(a) Prof. Vander Ribeiro Elme

BARUERI

2026

RESUMO

PIMENTA, Eduardo Ribeiro. **APLICAÇÃO DE MODELOS DE MACHINE LEARN PARA MELHORIA DA GESTÃO DE ESTOQUE, PREVISÃO DE DEMANDA E REDUÇÃO DO DESPERDÍCIO EM PEQUENOS RESTAURANTES**. Relato tecnológico apresentado à Faculdade de Tecnologia Padre Danilo José de Oliveira Ohl - Fatec Barueri - para obtenção do título de Tecnólogo em Gestão da Tecnologia da Informação, Barueri/SP, 2026.

Resumo

Palavras-Chave: Machine Learn. Gestão de Estoque. Desperdício de Alimentos.

ABSTRACT

PIMENTA, Eduardo Ribeiro. **APLICAÇÃO DE MODELOS DE MACHINE LEARN PARA MELHORIA DA GESTÃO DE ESTOQUE, PREVISÃO DE DEMANDA E REDUÇÃO DO DESPERDÍCIO EM PEQUENOS RESTAURANTES**. Relato tecnológico apresentado à Faculdade de Tecnologia Padre Danilo José de Oliveira Ohl - Fatec Barueri - para obtenção do título de Tecnólogo em Gestão da Tecnologia da Informação, Barueri/SP, 2026.

Abstract

Keywords: Machine Learn. Inventory Management. Food Waste.

SUMÁRIO

1 INTRODUÇÃO..... 6
2 REFERENCIAL TEÓRICO.....7
2.1 Gestão de estoques..... 7
2.2 Gestão de estoques em pequenos restaurantes..... 7
2.3 Desperdício de alimentos.....9
2.4 Inteligência Artificial..... 10
2.5 Machine Learning.....10
2.6 Previsão de demanda..... 11
3 METODOLOGIA.....12
3.1 Classificação e fundamentação da pesquisa.....12
3.2 Design Science Research (DSR) como procedimento metodológico.....13
3.3 Delimitação da pesquisa.....15
3.4 Instrumento e procedimento de coleta de dados.....15
3.5 Levantamento de requisitos e prototipação do artefato.....16
3.6 Procedimento de análise dos dados do formulário.....16
3.7 Protótipo e modelagem preditiva..... 17
3.8 Métricas de avaliação dos modelos.....18
4 PESQUISA DE CAMPO DIAGNÓSTICA: CARACTERIZAÇÃO E MAPEAMENTO DA OPERAÇÃO..... 19
5 ANÁLISE E RESULTADOS DA PESQUISA.....19
5.1 Resumo dos principais indicadores..... 19
5.2 Perfil dos estabelecimentos e controle de estoque..... 20
5.3 Previsão de demanda e influência de fatores externos.....20
5.4 Desperdício de alimentos..... 21
5.5 Margens de lucro e uso atual de tecnologia..... 21
5.6 Avaliações dos clientes e capacidade de crescimento da operação.....22
5.7 Relação dos resultados com a proposta do sistema..... 22
5.8 Conclusão da análise.....23
6 APLICAÇÃO DO ML EM UM RESTAURANTE FICTÍCIO.....24
6.1 Dados.....24
6.2 Engenharia de features.....25
6.3 Modelos avaliados..... 26
6.4 Resultados..... 26
6.4.1 Comparação geral de modelos.....26
6.4.2 Desempenho por prato..... 27
6.4.3 Resultados operacionais.....28
6.5 Viabilidade em restaurantes de pequeno porte..... 29
6.6 Limitações e trabalhos futuros..... 30
7 CONSIDERAÇÕES FINAIS..... 31
REFERÊNCIAS..... 32

1 INTRODUÇÃO

O setor de restaurantes e similares desempenha um papel relevante na economia brasileira, destacando-se pela expressiva presença de micro e pequenas empresas. Dados do Observatório Setorial Territorial do Sebrae ([s.d.]), com base em informações da Receita Federal, indicam que o segmento registrou uma taxa de criação de novos negócios de 49,4% em 2025. Além disso, até fevereiro de 2026, mais de 428 mil estabelecimentos encontravam-se ativos no país, sendo a maior parte composta por microempresas (ME) e microempreendedores individuais (MEI), evidenciando a importância econômica e social da atividade, especialmente no que se refere à geração de emprego, renda e desenvolvimento local.

Apesar do crescimento do setor, restaurantes de pequeno porte passam por diversos desafios relacionados à gestão do negócio, sendo essas as dificuldades no controle de estoque, alta concorrência, qualidade constante, logística eficiente e a manutenção do fluxo de caixa (VIANA, 2024). A gestão de estoques desempenha um papel fundamental no equilíbrio entre oferta e demanda, contribuindo para a disponibilidade de produtos e para a redução de custos operacionais. A falta de estoque pode comprometer o atendimento ao cliente, enquanto o excesso representa capital imobilizado e aumenta o risco de perdas, especialmente em produtos perecíveis. Dessa forma, a capacidade de prever a demanda torna-se um fator essencial para o gerenciamento eficiente dos estoques e para a tomada de decisões organizacionais (SLACK; BRANDON-JONES; JOHNSTON, 2018).

Tendo em vista o avanço da transformação digital, empresas de diferentes setores passaram a adotar tecnologias capazes de auxiliar na gestão e na tomada de decisões. Nesse contexto, uma das tecnologias que se destaca é o *Machine Learning* (aprendizado de máquina ou ML), uma área da Inteligência Artificial que utiliza algoritmos para analisar dados, identificar padrões e realizar previsões com base em informações históricas (BERGMANN, 2025). Diante desse cenário, surge o seguinte questionamento: “Em que medida modelos de *Machine Learning* podem contribuir para a previsão da demanda e para a melhoria da gestão de estoque em restaurantes de pequeno porte?”.

Com o propósito de responder a essa questão, este projeto propõe investigar a aplicação de ML como ferramenta de apoio à gestão de estoque em restaurantes de pequeno porte. Pretende-se analisar de que forma a utilização de

dados operacionais pode contribuir para a previsão da demanda e para a redução de desperdícios associados ao gerenciamento de insumos. Para tanto, o desenvolvimento do projeto contemplará aspectos como os modelos a serem avaliados, os dados a serem coletados, a pesquisa de campo, os critérios de avaliação dos resultados e a viabilidade de implementação.

2 REFERENCIAL TEÓRICO

2.1 Gestão de estoques

A gestão de estoques envolve o conjunto de decisões que buscam coordenar a demanda existente e a oferta de produtos ao longo do tempo, considerando as características de cada item, da operação e da própria demanda (WANKE, 2012). Três decisões centrais orientam esse processo: quando pedir, quanto pedir e quanto manter como estoque de segurança — respostas que dependem das circunstâncias de cada produto e não podem ser generalizadas para todo o estoque de uma organização.

O comportamento da demanda é uma das principais variáveis dessas decisões. Wanke (2012) demonstra que itens diferentes apresentam padrões de consumo e variabilidade distintos, de modo que um único parâmetro de reposição aplicado a todo o estoque tende a gerar distorções: itens de alto consumo exigem lógica diferente da aplicada a itens de baixo consumo. Essa constatação sustenta a necessidade de classificar os itens individualmente antes de definir políticas de estoque, e é a base conceitual adotada neste trabalho.

A gestão de estoques também depende do controle das movimentações — entradas, saídas e consumo — para que decisões de reposição sejam tomadas com base em informações confiáveis, sem o que a organização perde a capacidade de identificar quais itens exigem atenção e qual nível de estoque é compatível com sua demanda real (WANKE, 2012). Essa fundamentação orienta a discussão a seguir, voltada às particularidades da gestão de estoques em pequenos restaurantes.

2.2 Gestão de estoques em pequenos restaurantes

Em pequenos restaurantes, a gestão de estoques soma às decisões gerais de reposição a perecibilidade dos insumos, a limitação de pessoal e a variabilidade da demanda por prato. Controles precisam ser simples e adequados à quantidade reduzida de funcionários, que frequentemente acumulam funções de compra,

recebimento e preparo. Moreira et al. (2025), ao investigarem as barreiras na gestão de estoques de um restaurante familiar, identificaram controles predominantemente manuais e destacaram a influência da demanda sazonal e da cultura organizacional sobre os mecanismos de controle utilizados.

A perecibilidade dos insumos é outro aspecto central: ingredientes com vida útil curta não podem ser adquiridos apenas com base em descontos ou disponibilidade, sob risco de deterioração antes do consumo. Magalhães et al. (2022), em estudo de caso em um restaurante, aplicaram a classificação ABC sobre grupos de produtos do cardápio e compararam políticas de revisão contínua e periódica para apoiar a definição do estoque de reserva, demonstrando a aplicabilidade de técnicas de gestão de estoques mesmo em operações de pequeno porte.

Nem todo item do estoque de um restaurante compartilha, porém, essa urgência relacionada à deterioração. Itens não perecíveis — como canudos, guardanapos, embalagens e demais materiais descartáveis — não se deterioram com o tempo, mas ainda assim exigem controle adequado: sua falta compromete o atendimento tanto quanto a falta de um ingrediente, e seu consumo tende a acompanhar o volume de vendas e a composição do cardápio da mesma forma que o dos alimentos propriamente ditos. Essa distinção entre itens perecíveis e não perecíveis é outra expressão prática do princípio de que cada item deve ser gerenciado conforme suas próprias características de consumo, e não segundo uma política única aplicada a todo o estoque (WANKE, 2012).

A demanda de um restaurante, porém, não pode ser tratada como uma grandeza única: cada prato consome insumos em proporções diferentes, e um mesmo insumo costuma ser compartilhado entre vários pratos. Um item que compõe seis pratos diferentes tende a ter uma demanda agregada mais estável e previsível do que outro utilizado em apenas três receitas, cuja demanda soma variações menos correlacionadas entre si. Essa interdependência — em que a demanda de um insumo resulta da soma das vendas de vários itens do cardápio, e não da venda de um único produto — é reconhecida na literatura sobre controle de estoques como um dos aspectos que aumentam a complexidade de sistemas com múltiplos itens relacionados, ainda pouco explorado em aplicações práticas (BERGSMA; DE RUIJT; BHULAI, 2025). Essa característica reforça que a previsão de demanda de um pequeno restaurante não pode ser conduzida item a item de forma isolada, sendo

necessário considerar como os insumos se relacionam por meio das fichas técnicas dos pratos.

Essas particularidades — perecibilidade, limitação de estrutura e insumos compartilhados entre pratos — tornam a gestão de estoques em restaurantes especialmente sensível ao problema do desperdício de alimentos, discutido a seguir.

2.3 Desperdício de alimentos

O desperdício de alimentos refere-se à redução na quantidade ou qualidade dos alimentos decorrente de decisões tomadas por varejistas, serviços de alimentação e consumidores, distinguindo-se das perdas ocorridas em etapas anteriores da cadeia produtiva (FAO, 2024). Segundo o *Food Waste Index Report* 2024, aproximadamente 1,05 bilhão de toneladas de alimentos foram desperdiçadas em 2022 nos níveis de varejo, serviços de alimentação e domicílios — cerca de 19% dos alimentos disponíveis aos consumidores nesses segmentos —, dos quais aproximadamente 290 milhões de toneladas (28%) foram atribuídas ao setor de serviços de alimentação (UNEP, 2024). Além do impacto econômico direto, a FAO estima que as perdas e desperdício de alimentos estejam associados a cerca de 8% a 10% das emissões globais de gases de efeito estufa (FAO, 2024).

No ambiente de restaurantes, o desperdício pode ocorrer em diferentes momentos: durante o preparo, em pratos não servidos, em sobras deixadas pelos consumidores e em alimentos não vendidos. Maganha et al. (2025), em estudo de caso em um restaurante japonês, identificaram essas quatro situações e relacionaram o excesso de estoque a previsões inadequadas de demanda e vendas, apontando a previsão imprecisa como a causa mais provável do desperdício observado no estabelecimento. A revisão sistemática de Kaman et al. (2024) reforça que o desperdício em restaurantes tem natureza multifatorial, envolvendo tanto aspectos operacionais quanto comportamentais dos consumidores.

Essa multiplicidade de causas indica que a previsão de demanda pode contribuir para reduzir formas específicas de desperdício associadas ao excesso de produção ou de compra, mas não elimina outras causas, como erros de preparo ou porções mal dimensionadas (MAGANHA et al., 2025; KAMAN et al., 2024). Essa ressalva orienta a forma como a Inteligência Artificial é tratada neste trabalho: como recurso de apoio a um problema específico, e não como solução geral para o desperdício.

2.4 Inteligência Artificial

A Inteligência Artificial (IA) é definida pela OECD (2024) como um sistema baseado em máquina que, a partir de objetivos explícitos ou implícitos, utiliza informações recebidas para inferir como produzir previsões, conteúdos, recomendações ou decisões capazes de influenciar ambientes físicos ou virtuais, podendo apresentar diferentes níveis de autonomia e adaptação após sua implantação. Essa definição situa a IA como um campo amplo de métodos orientados à produção de resultados a partir de dados e objetivos previamente estabelecidos, e não apenas como automação de tarefas.

Dentro desse campo, o *Machine Learning* (ML) corresponde a um subconjunto de técnicas baseadas em métodos estatísticos, voltado à identificação de padrões diretamente a partir de dados históricos (OECD, 2022). Essa distinção é relevante para este trabalho: a IA é o conceito abrangente que fundamenta a utilização de sistemas de apoio à decisão, enquanto o ML é a técnica específica utilizada para transformar dados operacionais em previsões.

Em pequenos negócios, a adoção de IA envolve limitações relacionadas à disponibilidade de dados, recursos financeiros e conhecimento técnico, de modo que sua utilização deve estar associada a uma necessidade operacional concreta e a resultados compreensíveis pelos responsáveis pelo processo. Sistemas de IA devem ainda considerar aspectos de confiabilidade, transparência e gerenciamento de vieses (TABASSI, 2023), já que uma previsão incorreta pode influenciar diretamente uma decisão de compra e resultar em excesso de estoque ou falta de produtos. A revisão de Bergsma, de Ruijt e Bhulai (2025), que analisou 122 estudos sobre ML aplicado ao controle de estoques, identifica a previsão de demanda como uma das principais formas de integração entre ML e gestão de estoques, ao lado de desafios ainda existentes quanto à aplicação em situações reais.

2.5 Machine Learning

O *Machine Learning* constitui uma área da IA voltada ao desenvolvimento de sistemas capazes de aprender padrões a partir de dados de treinamento, em vez de depender exclusivamente de regras definidas manualmente (GÉRON, 2022). O processo típico envolve a preparação dos dados, o treinamento do modelo, sua avaliação com dados não utilizados no treinamento e, por fim, sua utilização para

produzir previsões — etapa em que a qualidade e a representatividade dos dados são tão determinantes quanto a técnica escolhida (GÉRON, 2022).

Entre as principais formas de aprendizado estão o supervisionado, o não supervisionado e o por reforço. No aprendizado supervisionado — o mais relevante para problemas de previsão —, o algoritmo aprende a relação entre variáveis de entrada e um resultado conhecido, podendo estimar categorias (classificação) ou valores numéricos (regressão), como a quantidade futura de demanda a partir de dados históricos de vendas (OECD, 2022). Um dos principais riscos nesse processo é o overfitting, quando o modelo se ajusta excessivamente aos dados de treinamento e perde capacidade de generalizar para novas situações (GÉRON, 2022).

Bergsma, de Ruijt e Bhulai (2025) identificam três formas de integrar ML ao controle de estoques: utilizá-lo para gerar estimativas de demanda antes da otimização; incorporá-lo diretamente aos modelos de otimização; ou empregá-lo, por meio de aprendizado por reforço, para definir políticas de estoque de forma dinâmica. Os autores também apontam que sistemas com múltiplos itens relacionados entre si — como ocorre quando vários produtos finais compartilham os mesmos insumos — ainda representam uma lacuna pouco explorada pelas aplicações práticas de ML em estoques, o que reforça a relevância de investigar esse aspecto no contexto de restaurantes, discutido na seção seguinte.

2.6 Previsão de demanda

A previsão de demanda consiste em estimar o comportamento futuro da procura por produtos a partir de dados históricos, com o objetivo de apoiar decisões de planejamento, e não de eliminar a incerteza sobre a demanda futura (ACKERMANN; SELLITTO, 2022). Entre os métodos disponíveis estão abordagens qualitativas, baseadas em julgamento de especialistas, e quantitativas, que utilizam séries temporais para identificar componentes como tendência e sazonalidade e projetá-los para períodos futuros (ACKERMANN; SELLITTO, 2022).

A qualidade de uma previsão é avaliada comparando valores previstos e observados por meio de métricas como o erro absoluto médio (MAE), a raiz do erro quadrático médio (RMSE) e o erro percentual absoluto médio (MAPE), cada uma mais adequada a determinados contextos de dados e de custo do erro (ACKERMANN; SELLITTO, 2022). Em restaurantes, essa escolha tem implicações

práticas: um erro que leva à superestimação da demanda de um insumo perecível tende a ser mais custoso do que o mesmo erro aplicado a um item não perecível.

Estudos recentes aplicam *Machine Learning* à previsão de vendas em restaurantes com resultados relevantes. Schmidt, Kabir e Hoque (2022) avaliaram diferentes modelos de ML para prever vendas em um restaurante de médio porte, destacando a importância da seleção de variáveis relacionadas a tendência e sazonalidade. Posch et al. (2022) desenvolveram modelos para prever vendas diárias de itens de cardápio a partir de dados de ponto de venda, identificando múltiplas sazonalidades e valores atípicos como características típicas desse tipo de série. Chae, Sheu e Park (2024) compararam modelos tradicionais, de ML e de *Deep Learning* em uma rede de restaurantes, constatando que o desempenho relativo entre eles varia conforme o período e as características dos dados analisados. Mais recentemente, Kim (2025) desenvolveu um sistema baseado em redes neurais para modelar individualmente centenas de itens de cardápio, incorporando dados meteorológicos além do histórico de vendas.

Esse nível de detalhamento por item é especialmente relevante para o problema investigado neste trabalho: como os insumos de um restaurante costumam ser compartilhados entre vários pratos, a demanda de cada ingrediente resulta da combinação das vendas de diferentes itens do cardápio, e não de um único produto. Modelar a demanda apenas no nível do prato, sem considerar essa relação entre receitas e insumos, tende a subestimar a complexidade real do problema de estoque em pequenos restaurantes — uma lacuna que a literatura sobre ML em controle de estoques ainda identifica como pouco explorada (BERGSMA; DE RUIJT; BHULAI, 2025).

Dessa forma, a previsão de demanda constitui uma etapa intermediária entre os dados históricos e as decisões de estoque: os dados descrevem o comportamento passado, o modelo produz uma estimativa e essa estimativa, considerada dentro de sua margem de erro, apoia — sem substituir — a avaliação do responsável pela gestão do restaurante.

3 METODOLOGIA

3.1 Classificação e fundamentação da pesquisa

Está pesquisa caracteriza-se, quanto à abordagem como qualitativa. Segundo Gil (2019), a pesquisa qualitativa busca compreender a experiência

humana de forma prática e acessível, sem se prender necessariamente a grandes volumes de dados ou a modelos clássicos rígidos, permitindo ao pesquisador captar, com clareza e objetividade a percepção dos sujeitos investigados sobre determinado fenômeno. Diante disso, a abordagem qualitativa se dá porque o formulário aplicado aos gestores dos restaurantes não tem como finalidade produzir conclusões estatísticas, mas sim evidenciar, a partir da experiência do profissional no dia a dia, que há a existência de problemas relacionados ao controle de estoque, previsibilidade da demanda e ao desperdício de alimentos, que fundamentam e justificam a proposta de solução apresentada neste trabalho.

Quanto aos objetivos, a pesquisa classifica-se como exploratória e descritiva. Conforme Gil (2019), a pesquisa exploratória tem como finalidade proporcionar maior familiaridade com o problema, tornando-a o mais explícito, sendo indicada quando o tema é pouco documentado na literatura; já a pesquisa descritiva tem como objetivo descrever as características de determinada população ou fenômeno, através de técnicas padronizadas de coleta de dados, como o questionário. O caráter exploratório vem devido a pouca investigação dessa realidade, de restaurantes de pequeno porte na região da Zona Oeste de São Paulo, enquanto o caráter descritivo se evidencia na forma como o estudo organiza e apresenta, de maneira sistemática, os dados referentes ao perfil selecionado, desafios e percepções relatadas pelos oito restaurantes que se proporam a participar da pesquisa.

Quanto à natureza, a pesquisa se classifica como aplicada. Marconi e Lakatos (2017) diferenciam a pesquisa pura (ou básica), voltada à ampliação do conhecimento científico sem preocupação imediata com sua aplicação prática, da pesquisa aplicada, ao qual objetivo é gerar conhecimentos à solução de problemas específicos. Este trabalho se enquadra nesta segunda categoria, uma vez que não se limita a comprovar teoricamente a existência de um problema, mas avança em direção ao entendimento de um artefato tecnológico como resposta prática a essa necessidade identificada.

3.2 Design Science Research (DSR) como procedimento metodológico

Como procedimento técnico central foi utilizado a abordagem de *Design Science Research* (DSR), método de pesquisa orientado à construção e avaliação de artefatos para efetuar a resolução do problema identificado. Segundo Dresch,

Lacerda e Antunes Júnior (2015), a DSR caracteriza-se por ser uma pesquisa orientada à solução de problemas específicos, não necessariamente em busca de uma solução ótima, mas de uma solução satisfatório para a situação apresentada, diferenciando de métodos tradicionais das ciências sociais por incorporar, além da compreensão do problema, o projeto de um artefato (produto, processo, método ou sistema) capaz de endereçá-lo. Reforçando a relevância e a atualidade do método. Sposito et al. (2024) destacam que a DSR desperta interesse crescente por auxiliar pessoas e organizações na otimização de resultados de seus esforços, sendo atraente para pesquisas de caráter tecnológico e aplicado, o que conversa exatamente com a proposta do TG.

A escolha do DSR se justifica pela própria estrutura do trabalho, que não se encerra após a identificação dos problemas de gestão de estoque, previsão de demanda e desperdício de alimentos em restaurantes participantes da pesquisa, mas avança para a proposição de um artefato tecnológico, um protótipo de plataforma digital, desenvolvido no Figma, a partir de requisitos funcionais e não funcionais levantados nas necessidades reais dos estabelecimentos. Esse artefato contempla, de forma integrada, funcionalidade de controle operacional de estoque, previsibilidade de demanda simulada com base em *Machine Learning*, além de mecanismos de acompanhamento de desperdício de alimentos, alinhando aos três eixos principais desta pesquisa. Essa lógica de condução de pesquisa encontra referência em Santana, Pereira e Mattos (2023), que aplicaram a DSR na elaboração de um artefato digital (Repositório institucional), através das etapas de identificação e conscientização do problema, revisão da literatura e concepção do problema, método que segundo os autores, atua como condutor de toda a pesquisa, promovendo a aproximação entre teoria e prática.

Essa metodologia liga-se ao estudo de Borges e Maia (2026), que aplicou a DSR ao desenvolvimento de um painel de controle interativo voltado à gestão de estoques institucionais, utilizando dados reais para orientar decisões de reposição e priorização de itens. Assim como no presente trabalho, os autores partiram da identificação de um problema de gestão de estoque em um contexto organizacional específico, em seguida, projetar e demonstrar um artefato tecnológico como resposta prática, reforçando a importância e atualidade da DSR como método adequado a pesquisas que articulam diagnóstico empírico e proposição de soluções digitais.

De forma geral, o desenvolvimento dessa pesquisa seguiu duas etapas complementares, alinhadas à lógica DSR: Etapa de conscientização do problema, na qual foi aplicado um formulário aos gestores de nove restaurantes de pequeno porte, com o objetivo de comprovar a existência e a relevância dos problemas relacionados à gestão de estoque, previsão de demanda e desperdício de alimento nesse segmento. A segunda etapa foi, concepção do artefato, na qual a partir dos requisitos funcionais elaborados com base nas necessidades identificadas, foi desenvolvido um protótipo de plataforma de gestão na ferramenta figma, contemplando funcionalidades de controle operacional de estoque, previsão de demanda baseada em *Machine Learning* e mecanismos de registro de desperdícios de insumos.

3.3 Delimitação da pesquisa

A pesquisa foi delimitada ao nicho de restaurantes de pequeno porte, caracterizados como estabelecimentos independentes (Não pertencentes a redes ou franquias), localizados na Zona Oeste de São Paulo. A amostra é composta por nove estabelecimentos, esse número é motivado pela necessidade de maior representatividade e robustez à comprovação da questão investigada, reduzindo os riscos de que as conclusões não reflitam a realidade dos estabelecimentos.

Os participantes da pesquisa são gestores, proprietários ou responsáveis diretos por cada estabelecimento, selecionados de forma intencional, por serem profissionais com autonomia decisória sobre compras, reposição de insumos e planejamento operacional, além de possuírem conhecimento prático e cotidiano das rotinas de estoque do negócio.

ADD o protótipo

3.4 Instrumento e procedimento de coleta de dados

Para a etapa de conscientização do problema, foi utilizado um formulário estruturado, (GIL, 2019), elaborado por meio da ferramenta Google Forms, composto por perguntas abertas, fechadas de múltipla escolha e de escala Likert variando de 1 a 5, (LIKERT, 1932), organizado em eixos temáticos como: caracterização do estabelecimento, principais desafios relacionados à gestão de estoque, métodos utilizados para estimar demanda, clareza sobre margem de lucro e diferenças entre canais de venda, impactos percebido do desperdício de

alimentos, ferramentas tecnológicas utilizadas, problemas operacionais que os gestores gostariam de resolver com tecnologia. O formulário teve como finalidade comprovar, com base em dados reais a existência da necessidade de uma ferramenta tecnológica de apoio à gestão de estoque, previsão de demanda e à redução do desperdício nos estabelecimentos participantes, não sendo utilizado para fins de comparação entre os casos.

A coleta foi realizada de forma remota, ao longo de aproximadamente três meses, por meio do envio do link do formulário via WhatsApp e Facebook aos gestores dos 9 restaurantes selecionados, com esclarecimento de eventuais dúvidas durante o preenchimento, de modo a garantir a correta compreensão dos itens e a qualidade das respostas obtidas.

3.5 Levantamento de requisitos e prototipação do artefato

A partir das análises das respostas obtidas, foram elaborados os requisitos funcionais da plataforma proposta, (SOMMERVILLE, 2019), correspondendo às funcionalidades que o sistema deve contemplar para responder às necessidades identificadas pelos gestores, com destaque em controle de estoque, na previsão de demanda e desperdícios de alimentos. A partir dos requisitos definidos, contempla desde funcionalidades básicas de cadastro e movimentação de produtos até funcionalidades avançadas de análise preditiva baseada em Inteligência Artificial e *Machine Learning*.

Com base nesses requisitos, foi desenvolvido um protótipo em Python, utilizando a biblioteca *Streamlit* (PRESSMAN; MAXIM, 2021), simulando o funcionamento de uma plataforma de gestão de estoque para restaurantes de pequeno porte. O protótipo foi alimentado com dados fictícios, elaborados para ilustrar de forma visual e interativa, como as informações operacionais (Movimentações de estoque, alertas de reposição, histórico de vendas) e preditivas (Previsão de demanda, sugestões de compras) seriam apresentadas e utilizadas pelo gestor para auxiliar a tomada de decisão.

3.6 Procedimento de análise dos dados do formulário

A análise das informações coletadas por meio do formulário aplicado aos gestores dos nove estabelecimentos foi estruturada sob uma abordagem descritiva e qualitativa (CRESWELL; CRESWELL, 2021), com o propósito de diagnosticar a

realidade operacional e fundamentar o levantamento de requisitos do artefato. Os dados brutos extraídos da plataforma Google Forms foram organizados e tabulados para permitir a categorização temática das respostas, nomeadas: caracterização do perfil operacional, dinâmicas de controle de estoque, práticas de previsão de demanda, percepção de desperdícios e nível de maturidade tecnológica das empresas.

Para garantir a clareza e a objetividade na exposição dos resultados, combina descrições narrativas com recursos de visualização gráfica e tabular, conforme (GIL; 2019). As variáveis de escolha múltipla são sintetizadas em gráficos de barras e tabelas de frequência, facilitando a identificação de padrões e gargalos comuns entre os participantes. Já as questões avaliadas por meio de escalas de Likert foram submetidas ao cálculo de médias pontuais e distribuição de frequências, permitindo mensurar a intensidade do impacto percebido de fatores externos e perdas operacionais. Esta estruturação assegura o rigor no tratamento dos dados de campo, servindo como elo de ligação entre a identificação do problema e a concepção das funcionalidades da plataforma proposta.

3.7 Protótipo e modelagem preditiva

Para a concepção do artefato exigido pela metodologia DSR, o protótipo foi construído em linguagem Python e estruturado com a biblioteca Streamlite, permitindo a criação de uma aplicação web interativa voltada ao suporte à decisão. Devido à indisponibilidade de informações abertas com detalhamento operacional do setor, foi desenvolvido um gerador de dados sintéticos capaz de reproduzir os padrões de demanda descritos na literatura. O conjunto gerado abrangeu um ano de operação diária contendo cinco pratos do cardápio, incorporando sazonalidades semanal e anual, tendências de consumo, feriados nacionais, diferenças na temperatura e efeitos promocionais. A integração com a camada operacional deu-se por meio de uma ficha técnica estruturada com 21 relações de consumo entre pratos e dez insumos do estoque.

Para a modelagem preditiva, foram estruturadas 15 variáveis explicativas divididas entre padrões temporais do calendário, variáveis e métricas históricas de vendas, (GÉRON, 2022). A fim de evitar o vazamento de dados, aplicou-se o deslocamento temporal de um dia em todas as métricas históricas, e a validação foi realizada com a separação dos últimos 30 dias do histórico como conjunto de testes.

Foram avaliados os algoritmos de Média Móvel (baseline), Regressão Ridge, Random Forest e *LightGBM*, além de modelos combinados por ensemble (GÉRON, 2022).

O algoritmo de Ensemble Ponderado alcançou o melhor desempenho, obtendo um Erro Percentual Absoluto Ponderado (WAPE) de 13,28% e Erro Absoluto Médio (MAE) de 7,17 pratos por dia, representando uma redução de aproximadamente 41% no erro em comparação ao método tradicional de média móvel. Por fim, o protótipo conecta os resultados desse modelo preditivo às fichas técnicas, calculando automaticamente as necessidades de reposição e gerando relatórios com sugestões de compra e custos estimados para apoiar as decisões de abastecimento do gestor.

3.8 Métricas de avaliação dos modelos

A medição do desempenho e a validação comparativa dos algoritmos preditivos fundamentaram-se em métricas consolidadas na literatura de previsão de demanda e séries temporais (ACKERMANN; SELLITTO, 2022; HYNDMAN; ATHANASOPOULOS, 2021). Para quantificar a precisão e as divergências entre os valores de demanda previstos e os observados no período de teste, utilizaram-se o Erro Absoluto Médio (MAE), a Raiz do Erro Quadrático Médio (RMSE), o Erro Percentual Absoluto Médio (MAPE), o Erro Percentual Absoluto Ponderado (WAPE) e o viés preditivo (Bias).

O Erro Absoluto Médio expressa a magnitude média dos erros em termos absolutos na mesma unidade da variável original, quantificando diretamente quantos pratos o modelo erra por dia sem penalizar desproporcionalmente desvios incomuns. A Raiz do Erro Quadrático Médio penaliza erros de maior magnitude de forma mais severa devido à elevação ao quadrado das diferenças, tornando-se uma métrica sensível à presença de picos atípicos de demanda. Para avaliar a precisão relativa em termos percentuais, calculou-se o Erro Percentual Absoluto Médio, suplementado pelo Erro Percentual Absoluto Ponderado, que pondera o erro total acumulado pelo volume total de vendas do período, contornando a distorção gerada por divisões por valores baixos em dias de pouca movimentação. Por fim, o viés preditivo foi calculado para monitorar se os modelos apresentaram tendências sistemáticas de subestimar ou superestimar a demanda diária, aspecto crítico para

evitar compras insuficientes ou acúmulo desnecessário de estoque perecível, (ACKERMANN; SELLITTO, 2022) .

4 PESQUISA DE CAMPO DIAGNÓSTICA: CARACTERIZAÇÃO E MAPEAMENTO DA OPERAÇÃO

Para fundamentar a etapa de conscientização do problema na abordagem *Design Science Research* (DSR), realizou-se um diagnóstico da realidade operacional do setor por meio da aplicação de um formulário estruturado de pesquisa de campo, aplicado de forma remota via Google Forms ao gestores e proprietários de nove restaurantes localizados na Zona Oeste de São Paulo.

A escolha do formulário como instrumento de coleta de dados justifica-se pela obtenção de retirar informações diretas, padronizadas e comparáveis junto aos profissionais que possuem rotinas operacionais intensas e restrição de tempo. Por meio do formulário, foi possível assegurar a participação de gestores com autonomia nos processos de decisão, compras e planejamento, permitindo registrar a percepção prática dos estabelecimentos.

O instrumento foi estruturado em 11 questões organizadas entre múltipla escolha com campo aberto para especificação, escalas de mediação de atitude do tipo Likert variando de 1 a 5 e perguntas discursivas opcionais, o conjunto de pesquisas abrangeu os seguintes eixos resumidos;

- Caracterização do estabelecimento e equipes: Perguntas sobre o modelo de negócio (restaurante próprio, *dark kitchen, delivery*) e o total de colaboradores, visando identificar o porte da empresa e o grau de centralização de tarefas atribuídas ao gestor.
- Dificuldades no controle de estoque: Maiores dificuldades com insumos (rupturas em dias de pico, perdas de perecíveis, falta de espaço ou ausência de controle estruturado).
- Métodos de Estimativa de demanda: Forma como os restaurantes projeta suas vendas diárias.
- Percepção de margens e canais de vendas: Clareza da margem de lucro por prato e sobre o conhecimento da diferença real de rentabilidade entre vendas diretas e canais de marketplace.

- Consolidações dos feedbacks e gargalos operacionais: Acompanhamento das avaliações dos clientes e sobre qual processo operacional quebraria se caso o movimento dobrasse no dia seguinte.
- Fatores externos e impacto do desperdício: Perguntas em Likert (1 a 5), para mensurar em que medidas variáveis (clima, eventos, feriados) alteram a operação e quanto o desperdício impacta financeiramente para o negócio.
- Tecnologia e demandas de intervenção: Perguntas abertas sobre as ferramentas de tecnologia atualmente consideradas indispensáveis e sobre qual dor operacional específica o gestor gostaria de resolver por meio da tecnologia.

5 ANÁLISE E RESULTADOS DA PESQUISA

A pesquisa foi realizada com 9 restaurantes para identificar dificuldades relacionadas ao controle de estoque, à previsão de demanda, ao desperdício de alimentos, ao uso de tecnologia e à capacidade operacional. Neste Relato Tecnológico, os resultados são utilizados como diagnóstico inicial do contexto estudado e como subsídio para justificar e orientar a proposta de um sistema de apoio à previsão de demanda e ao controle de estoque com *Machine Learning*.

5.1 Resumo dos principais indicadores

Indicador	Resultado	Interpretação
Previsão de demanda	1 restaurante (11,1%) usa relatórios de PDV/ERP	Há espaço para uma previsão mais estruturada
Desperdício	2 (22,2%) citam perecíveis como desafio	Existem perdas específicas relacionadas a perecíveis
Controle de estoque	Apenas 3 (33,3%) têm controle estruturado	Reforça a necessidade de centralização e alertas
Fatores externos	6 (66,7%) deram notas de 3 a 5	Variáveis externas podem contribuir para a previsão

5.2 Perfil dos estabelecimentos e controle de estoque

Dos 9 estabelecimentos, 7 (77,8%) são restaurantes próprios e independentes, 1 (11,1%) é dark kitchen com delivery exclusivo e 1 (11,1%) possui restaurante próprio com delivery. Em relação às equipes, 5 (55,6%) possuem até 5 funcionários e 2 (22,2%) têm mais de 30. A amostra concentra operações menores, mas também contempla negócios de maior porte.

Os resultados mostram diferentes níveis de controle de estoque. Três restaurantes (33,3%) não apontaram dificuldades relevantes, mas 2 (22,2%) declararam não possuir controle estruturado. Também foram citados falta de espaço (11,1%), falta de insumos em dias de pico (11,1%) e desperdício de perecíveis (22,2%). Esses dados indicam riscos de falta de produtos, compras inadequadas e perdas. Para a proposta tecnológica, apontam a importância de registrar e centralizar entradas e saídas, acompanhar níveis de estoque e emitir alertas de reposição. Essas necessidades derivam do diagnóstico, e sua eficácia deverá ser avaliada caso o sistema seja implementado.

5.3 Previsão de demanda e influência de fatores externos

Quatro restaurantes (44,4%) não realizam previsão de demanda, 3 (33,3%) utilizam experiência/intuição, 1 (11,1%) usa reservas antecipadas e apenas 1 (11,1%) utiliza relatórios de PDV/ERP. Assim, 88,9% ainda dependem de métodos pouco estruturados.

Esse resultado é central para o projeto: uma solução baseada em *Machine Learning* poderá analisar o histórico de vendas e identificar padrões para estimar a demanda futura. A inclusão de variáveis como dia da semana, sazonalidade, feriados e eventos poderá ser considerada no desenvolvimento do modelo (KHAN et al., 2024), com o objetivo de apoiar decisões de compra e produção e reduzir o risco de faltas ou excessos (SANTOS et al., 2023). A pesquisa identifica essa necessidade, mas não comprova, por si só, a precisão de um modelo ainda não testado.

A influência de fatores externos, como clima, eventos e feriados, teve média de 3,11. Seis restaurantes (66,7%) deram notas entre 3 e 5, enquanto 3 (33,3%) deram nota 1. O resultado sugere que fatores externos podem influenciar a demanda em parte dos estabelecimentos e justifica avaliar sua inclusão nos modelos de previsão, além do histórico de vendas (KHAN et al., 2024). Como as

respostas variaram, essas variáveis não devem ser tratadas como igualmente relevantes para todos os restaurantes; sua utilidade precisará ser verificada conforme os dados disponíveis.

5.4 Desperdício de alimentos

O impacto percebido do desperdício teve média de 1,89 em uma escala de 1 a 5. Quatro restaurantes (44,4%) deram nota 1, dois (22,2%) nota 2 e três (33,3%) nota 3; nenhum atribuiu 4 ou 5. Apesar da média relativamente baixa, 2 estabelecimentos (22,2%) apontaram o desperdício de perecíveis como principal desafio de estoque. Os resultados indicam que o desperdício não foi percebido como elevado por toda a amostra, mas existem dificuldades específicas que justificam avaliar recursos para acompanhar consumo, validade e giro dos produtos.

5.5 Margens de lucro e uso atual de tecnologia

Cinco participantes (55,6%) analisam regularmente a margem de lucro para ajustar o cardápio, enquanto 4 (44,4%) possuem apenas uma noção das margens. Sobre pedidos de iFood versus pedidos próprios, 3 (33,3%) calculam a diferença com precisão, 3 (33,3%) trabalham com estimativa e 3 (33,3%) não utilizam marketplaces. Entre os estabelecimentos que utilizam ou avaliam marketplaces, metade calcula a diferença de margem com precisão e metade trabalha com estimativa. A integração de vendas, custos, taxas e estoque poderia ampliar a análise da rentabilidade por produto e canal. Como essa funcionalidade não constitui necessariamente o foco principal, sua inclusão deve depender do escopo definido para o sistema.

O nível de digitalização é heterogêneo: foram citados Excel, Rodo digital, redes sociais, Linx Menew e Cloudfy, enquanto 1 participante afirmou não possuir ferramenta de tecnologia para gestão. Também surgiram demandas por sistemas integrados e integração com plataformas de delivery. Parte dos restaurantes já possui dados digitais que poderiam, dependendo da disponibilidade e da compatibilidade, alimentar uma solução de previsão e controle de estoque, enquanto outros dependem de ferramentas isoladas. Esse cenário aponta para a importância de avaliar a integração com sistemas existentes e priorizar uma solução de uso simples. A viabilidade dessas integrações deverá ser confirmada durante o desenvolvimento.

5.6 Avaliações dos clientes e capacidade de crescimento da operação

Nenhum restaurante possui um processo totalmente automatizado para consolidar avaliações. Seis (66,7%) acompanham manualmente as plataformas e 3 (33,3%) leem as avaliações apenas quando têm tempo. Embora não seja o foco principal do sistema proposto, essa informação indica uma possibilidade de evolução futura: mudanças na aceitação dos produtos poderiam, se houver meios adequados de coleta e integração, apoiar decisões de produção e estoque. Portanto, o acompanhamento automatizado de avaliações pode ser tratado como oportunidade futura, e não como funcionalidade já definida.

Se o movimento dobrasse, 3 restaurantes (33,3%) apontaram a equipe/escala como principal ponto de pressão; 2 (22,2%) indicaram pedidos da cozinha/delivery; 1 (11,1%) citou pedidos, financeiro e fechamento de caixa; 2 (22,2%) não souberam indicar e 1 (11,1%) afirmou que a situação não ocorre devido às reservas antecipadas. O resultado mostra que o crescimento da demanda pode pressionar diferentes áreas da operação.

5.7 Relação dos resultados com a proposta do sistema

A pesquisa evidencia quatro necessidades principais para o sistema:

1. Previsão de demanda: 44,4% não realizam previsão, 33,3% dependem da experiência/intuição e apenas 11,1% utilizam relatórios de PDV/ERP. Há espaço para uma previsão baseada em dados.
2. Controle de estoque: 22,2% não possuem controle estruturado e outros relatam falta de insumos e desperdício de perecíveis. É importante acompanhar entradas, saídas, níveis e perdas.
3. Redução de desperdícios: a média do impacto percebido foi 1,89/5, mas 22,2% apontaram perecíveis como principal desafio de estoque. O problema é relevante, embora não seja percebido como alto por toda a amostra.
4. Integração tecnológica: os restaurantes apresentam diferentes níveis de digitalização e parte deles já utiliza sistemas como Linx Menew e Cloudfy, o que cria possibilidade de integrar dados de vendas e operação ao sistema proposto.

A partir do diagnóstico, o sistema é proposto como ferramenta de apoio à decisão. O uso de *Machine Learning* para analisar o histórico de vendas e outras

variáveis poderá gerar estimativas de demanda e apoiar decisões de compras, produção e reposição. A expectativa é contribuir para evitar excessos e faltas e apoiar a redução do desperdício; esses benefícios, porém, precisarão ser verificados por testes e avaliação após a implementação.

5.8 Conclusão da análise

De maneira geral, os restaurantes pesquisados apresentam diferentes níveis de maturidade tecnológica, e as principais lacunas identificadas estão na previsão de demanda e na estruturação do controle de estoque. Um achado relevante é que apenas 1 dos 9 estabelecimentos (11,1%) utiliza relatórios de PDV/ERP para estimar a demanda. Esse resultado ajuda a justificar a proposta de uma solução orientada por dados, sem permitir generalizações para todos os restaurantes.

A média do impacto percebido do desperdício de alimentos foi de 1,89, em uma escala de 1 a 5, enquanto a influência média de fatores externos sobre a demanda foi de 3,11. Além disso, 2 estabelecimentos (22,2%) apontaram o desperdício de perecíveis como um dos principais desafios relacionados ao estoque. Também foi identificado o uso do sistema Cloudfy entre as ferramentas tecnológicas utilizadas pelos restaurantes pesquisados.

O cenário identificado sustenta a pertinência de desenvolver e avaliar uma solução baseada em *Machine Learning* para transformar dados operacionais em previsões e recomendações de estoque. A solução tem como objetivo apoiar decisões, reduzir o risco de compras ou produções excessivas e de falta de insumos e contribuir para o controle do desperdício (SANTOS et al., 2023). Tais contribuições são objetivos esperados e dependem da implementação e da avaliação do sistema.

A pesquisa contou com apenas 9 participantes e, portanto, não representa necessariamente a realidade de todos os restaurantes. Além do tamanho reduzido da amostra, os resultados refletem as respostas dos estabelecimentos consultados e devem ser interpretados como um diagnóstico inicial. Ainda assim, oferecem evidências práticas para fundamentar a proposta tecnológica e orientar prioridades de desenvolvimento.

6 APLICAÇÃO DO ML EM UM RESTAURANTE FICTÍCIO

6.1 Dados

Como dados reais de restaurantes são proprietários e raramente disponíveis em formato estruturado, foi construído um gerador sintético que reproduz padrões documentados na literatura de demanda em food service. O gerador produz um ano de operação para cinco pratos, totalizando 1.825 observações diárias. Cada prato recebe um perfil próprio que combina três camadas de sazonalidade, conforme resumido na tabela abaixo.

Camada	Comportamento	Exemplo
Semanal	Curva de 7 dias diferente por prato	Feijoada +85% no fim de semana;salada -25% no domingo
Anual	Perfil de 12 meses por prato	Feijoada 175% em julho, 55% em dezembro; salada o inverso
Tendência	Crescimento/queda mensal	Strogonoff -1,2%/mês; frango grelhado +2,8%/mês

Sobreposto a isso, o gerador adiciona feriados nacionais brasileiros calculados dinamicamente via algoritmo de Meeus, que resolve a Páscoa móvel e permite trabalhar qualquer ano sem lista fixa. Adiciona também temperatura sintética com ciclo anual e ruído autocorrelacionado, à qual cada prato responde com sensibilidade própria; promoções aleatórias de dois a quatro dias com boost entre 20% e 45%; uma mudança de regime aos 60% do período, em que strogonoff perde 15% e salada ganha 15%; e 1,5% de outliers, com picos entre 1,5 e 2,3 vezes a demanda normal.

O cadastro do restaurante inclui dez insumos com unidades e custos unitários, cinco pratos e uma ficha técnica com 21 relações de prato-insumo, cada uma expressando quantos quilogramas do insumo são consumidos por porção vendida. Essa ficha é o elo que permite traduzir previsão de prato em necessidade de insumo, e sem ela o sistema não teria como conectar a camada preditiva à camada operacional.

6.2 Engenharia de features

O modelo consome 15 features organizadas em três famílias, conforme a tabela abaixo.

Família	Features	Propósito
Calendário	dia semana, mês, dia ano, fim_de_semana, feriado	Capturar padrões cíclicos e eventos
Exógenas	temperatura, promoção	Incorporar fatores externos que afetam demanda
Históricas	lag_1, lag_2, lag_7, lag_14, mm_7, mm_14, mm_30, std_7, dias_desde_inicio	Capturar dependência temporal e tendência

A variável prato é tratada como categórica nativa no LightGBM e como one-hot na Regressão Ridge, evitando que o modelo interprete a identidade do prato como uma relação numérica.

Todas as features históricas usam deslocamento de um dia antes de qualquer agregação, o que impede vazamento temporal. A previsão para o dia d nunca usa informação do próprio dia d. A validação é temporal: os últimos 30 dias do histórico são separados como conjunto de teste, e o modelo é treinado apenas com os dados anteriores. Essa escolha é central para séries temporais, já que um split aleatório quebraria a estrutura cronológica e produziria métricas otimistas que não se sustentam em operação real.

6.3 Modelos avaliados

Foram treinados quatro modelos individuais e dois ensembles, todos avaliados sobre o mesmo conjunto de validação temporal.

Modelo	Descrição	Papel no projeto

Baseline	Média móvel de 7 dias	Referência mínima
Ridge	Regressão linear com regularização L2 + one-hot do prato	Modelo simples e interpretável
Random Forest	400 árvores, min_samples_leaf=2	Não-linearidade, robustez
LightGBM	400 estimadores, learning_rate=0,04, num_leaves=15	Alta performance tabular
Ensemble simples	Média aritmética dos 3 modelos	Redução de variância
Ensemble ponderado	Média com pesos 1/WAPE	Prioriza quem acerta mais

A justificativa para o ensemble repousa no fato de que cada algoritmo erra de forma diferente. O Ridge captura tendências lineares, o Random Forest lida bem com não-linearidades e interações, e o LightGBM é eficiente em padrões de alta ordem. A média das previsões tende a cancelar erros compensatórios, e a ponderação pelo desempenho dá mais voz a quem acerta mais sem descartar completamente os demais.

6.4 Resultados

6.4.1 Comparação geral de modelos

A avaliação sobre os últimos 30 dias produziu a tabela abaixo, ordenada por WAPE (menor é melhor).

Modelo	MAE	RMSE	MAPE (%)	WAPE (%)	Viés
Ensemble ponderado	7,17	12,27	12,88	13,28	-1,67

Ensemble simples	7,19	12,29	12,94	13,32	-1,64
Random Forest	7,25	12,05	13,15	13,43	-1,37
LightGBM	7,43	12,71	12,83	13,76	-2,87
Ridge	8,25	13,35	15,45	15,29	-0,69
Baseline	12,16	17,80	22,06	22,51	-0,36

A leitura desses números merece atenção em três frentes. Primeiro, a redução de 22,51% para 13,28% no WAPE representa queda de aproximadamente 41% no erro em relação ao método ingênuo, o que quantifica o ganho real do *machine learning* sobre a prática comum de usar médias históricas. Segundo, o erro absoluto médio de 7,17 pratos por dia, em uma operação que vende cerca de 170 pratos diários, corresponde a menos de 5% de erro absoluto, patamar aceitável para decisões de compra e produção. Terceiro, o viés próximo de zero nos ensembles indica que o modelo não tem tendência sistemática a superestimar nem a subestimar, o que é importante porque viés consistente em uma direção gera decisões enviesadas.

Vale notar que o LightGBM, apesar de competitivo, apresentou viés negativo de 2,87, quase o dobro dos demais. Isso indica subestimação sistemática e foi o principal motivo para não adotá-lo isoladamente, mesmo com MAPE ligeiramente inferior ao do ensemble.

6.4.2 Desempenho por prato

A desagregação por prato revela heterogeneidade relevante.

Prato	MAE	WAPE (%)	Viés	Comentário

Lasanha	4,21	10,71	+0,40	Melhor desempenho; padrão estável
Frango grelhado	7,74	11,69	-2,04	Tendência forte de crescimento; modelo corre atrás
Strogonoff	8,01	12,84	-1,35	Queda gradual no período; boa captura
Salada caesar	3,13	13,72	-1,04	Sazonalidade extrema (5× entre inverno/verão)
Feijoada	12,77	16,11	-4,33	Caso mais desafiador; sazonalidade forte + eventos

A lasanha teve o melhor desempenho, com WAPE de 10,71% e viés praticamente nulo. A feijoada foi o caso mais desafiador, com WAPE de 16,11% e viés negativo de 4,33, reflexo da combinação de forte sazonalidade anual com efeito acentuado de fim de semana e outliers frequentes em eventos. A salada teve WAPE intermediário, o que faz sentido dado seu perfil sazonal extremo, difícil de capturar com precisão em apenas um ano de dados.

6.4.3 Resultados operacionais

A distribuição dos insumos por status mostra que o sistema discrimina situações, não classificando tudo como falta nem como excesso, o que permite ao gestor priorizar ações. Os insumos em falta e suas respectivas sugestões de compra estão na tabela abaixo.

Insumo	Necessidade 7d	Estoque atual	Saldo	Compra sugerida	Custo

Carne bovina	225,45 kg	85,8 kg	-139,65 kg	153,62 kg	R$ 5.376,70
Queijo	68,30 kg	20,0 kg	-48,30 kg	53,13 kg	R$ 2.125,20
Feijão	104,75 kg	36,5 kg	-68,25 kg	75,08 kg	R$ 600,64
Batata	89,20 kg	70,0 kg	-19,20 kg	21,12 kg	R$ 126,72
Frango	206,90 kg	199,5 kg	-7,40 kg	8,14 kg	R$ 122,10
Arroz	163,65 kg	147,6 kg	-16,05 kg	17,66 kg	R$ 88,30
Alface	47,35 kg	40,0 kg	-7,35 kg	8,09 kg	R$ 40,45
Tomate	70,35 kg	70,0 kg	-0,35 kg	0,38 kg	R$ 2,66

6.5 Viabilidade em restaurantes de pequeno porte

A viabilidade técnica deste sistema em restaurantes de pequeno porte é alta, e a análise precisa separar o que é barato do que é desafiador. Do lado dos custos, a stack é inteiramente aberta: Python, scikit-learn, LightGBM e Streamlit são gratuitos e amplamente documentados. O treino completo roda em aproximadamente dez segundos em um notebook comum, e a inferência diária leva menos de um segundo. Não há exigência de GPU nem de infraestrutura em nuvem paga. A interface foi desenhada para gestores não-técnicos, com formulários, tabelas coloridas e alertas em linguagem natural. Um restaurante com cinco ou cinquenta pratos usa o mesmo pipeline, bastando atualizar a ficha técnica.

Do lado dos desafios, três pré-requisitos operacionais precisam estar presentes para o sistema funcionar, conforme a tabela abaixo.

Pré-requisito	Por quê	Como resolver

Vendas digitalizadas	Sem dados de venda, o modelo não tem o que aprender	Exportar CSV do PDV ou integrar via API
Ficha técnica documentada	Converte previsão de prato em necessidade de insumo	2-4 semanas observando preparo dos pratos top
Registro de perdas	Alimenta o módulo de desperdício	Mudança cultural; sistema ajuda a criar o hábito

Sobre o retorno esperado, um restaurante que vende 150 refeições por dia e gasta R$40.000 mensais em insumos,com desperdício estimado em R$8640 e R$960 por mês mesmo com uma redução conservadora de 20% no desperdício. A redução de ruptura adicionaria margem ainda maior, já que cada venda perdida por falta de insumo representa receita não realizada. O investimento é apenas tempo de setup e treinamento, sem licenciamento recorrente.

Comparado com ERPs comerciais que cobram entre R$300 e R$1.500 mensais, este projeto se diferencia em dois pontos. Primeiro, a previsão é baseada em *machine learning*, enquanto a maioria dos ERPs de restaurante usa regras fixas de estoque mínimo e ponto de pedido, sem modelar sazonalidade nem tendência. Segundo, a ficha técnica é integrada à previsão, permitindo traduzir demanda prevista em necessidade de insumos automaticamente, o que poucos sistemas comerciais fazem.

6.6 Limitações e trabalhos futuros

Os dados são sintéticos e, embora reproduzam padrões documentados, não substituem validação em operação real. O horizonte de previsão de sete dias é adequado para decisões de compra semanal, mas previsões mais longas degradam rapidamente, com erro crescendo entre 15% e 20% por dia adicional. O sistema não modela lead time variável de fornecedores, assumindo que entregas ocorrem conforme prometido. A ficha técnica é estática, enquanto em produção ela varia com sazonalidade de ingredientes e mudanças de fornecedor. Pratos com tendência forte

de crescimento, como o frango grelhado, são sistematicamente subestimados, o que exige retreino mais frequente ou features adicionais.

Como trabalhos futuros, destacam-se três frentes. A primeira é a integração com PDV real, eliminando a necessidade de importação manual. A segunda é a construção de um classificador de risco de desperdício por insumo e dia, adicionando uma segunda frente de *machine learning* ao projeto. A terceira é a otimização de compras com programação linear, considerando múltiplos fornecedores e restrições de orçamento.

7 CONSIDERAÇÕES FINAIS

O projeto demonstra que *machine learning* aplicado a restaurantes é viável e produz resultados mensuráveis. A redução de 41% no erro de previsão em relação ao baseline é substancial e defensável, obtida com uma stack gratuita e um pipeline que roda em segundos. A tradução automática de previsão em necessidade de insumos fecha o ciclo entre predição e decisão, o que diferencia este trabalho de abordagens que param na modelagem. A interface acessível a gestores não-técnicos reduz a barreira de adoção, e a viabilidade financeira é clara para restaurantes de pequeno porte com operação minimamente digitalizada. O principal obstáculo não é tecnológico, mas cultural: registrar vendas, insumos e perdas de forma consistente. Onde essa disciplina existe, o sistema pode entregar valor imediato e recorrente.

REFERÊNCIAS

ACKERMANN, Andres E. F.; SELLITTO, Miguel A. Métodos de previsão de demanda: uma revisão da literatura. **Innovar**, v. 32, n. 85, p. 83-99, 2022. DOI: https://doi.org/10.15446/innovar.v32n85.100979. Acesso em: 28 set. 2026.

BERGMANN, Dave. O que é aprendizado de máquina? ***IBM Think***, 2025. Disponível em: https://www.ibm.com/br-pt/think/topics/machine-learning. Acesso em: 9 jun. 2026.

BERGSMA, Ritsaart; DE RUIJT, Corné; BHULAI, Sandjai. *A systematic review of machine learning approaches in inventory control optimization.* ***Operations Research Perspectives***, v. 15, 100367, 2025. DOI: https://doi.org/10.1016/j.orp.2025.100367. Acesso em: 28 set. 2026.

BORGES, T. M.; MAIA, L. C. C. Processo de gestão de estoques e espaços de armazenamento da UFU. Revista Inovação, **Projetos e Tecnologias – IPTEC**, São Paulo, v. 14, n. 1, p. 1-17, jan./jun. 2026.

CHAE, Bongsug (Kevin); SHEU, Chwen; PARK, Eunhye Olivia. *The value of data, machine learning, and deep learning in restaurant demand forecasting: insights and lessons learned from a large restaurant chain.* ***Decision Support Systems***, v. 184, 114291, 2024. DOI: https://doi.org/10.1016/j.dss.2024.114291. Acesso em: 14 set. 2026.

CRESWELL, John W.; CRESWELL, J. David. **Projeto de pesquisa**: métodos qualitativo, quantitativo e misto. 5. ed. Porto Alegre: Penso, 2021.

DRESCH, Aline; LACERDA, Daniel Pacheco; ANTUNES JÚNIOR, José Antônio Valle. ***Design science research***: método de pesquisa para avanço da ciência e tecnologia. Porto Alegre: Bookman, 2015.

FAO. ***Food loss and food waste****. **Rome**: Food and Agriculture Organization of the United Nations,* 2024. Disponível em: https://www.fao.org/policy-support/policy-themes/food-loss-and-food-waste/en. Acesso em: 13 set. 2026.

GÉRON, Aurélien. ***Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow****. 3. ed. Sebastopol: O'Reilly Media*, 2022.

GIL, Antonio Carlos. **Métodos e técnicas de pesquisa social**. 7. ed. São Paulo: Atlas, 2019.

HYNDMAN, Rob J.; ATHANASOPOULOS, George. ***Forecasting****: principles and practice. 3rd ed. Melbourne: OTexts*, 2021.

KAMAN, Gizem Sultan et al. T*he strategy food waste in restaurants: a systematic literature review.* ***Trends in Food Science & Technology****,* v. 151, 104625, 2024. DOI: https://doi.org/10.1016/j.tifs.2024.104625. Acesso em: 16 set. 2026.

KIM, Sangoh. *Development of an AI-based restaurant menu demand prediction model utilizing sales and meteorological data.* ***Food Science and Biotechnology,*** v. 34, n. 15, p. 3597-3606, 2025. DOI: https://doi.org/10.1007/s10068-025-01956-2. Acesso em: 28 set. 2026.

LIKERT, Rensis. *A technique for the measurement of attitudes.* ***Archives of Psychology***, v. 22, n. 140, p. 1-55, 1932.

MAGALHÃES, Mariana Carrilho et al. Aplicação de técnicas de gestão de estoques em uma pequena empresa: o caso de um restaurante. **Zeiki - Revista Interdisciplinar da Unemat Barra do Bugres**, 2022. Disponível em: https://periodicos.unemat.br/index.php/zeiki/article/view/6154. Acesso em: 16 set. 2026.

MAGANHA, Isabela et al. *Unveiling food waste: a case study of a restaurant specializing in Japanese cuisine in Brazil.* ***Waste Management Bulletin***, v. 3, n. 4, 100261, 2025. DOI: https://doi.org/10.1016/j.wmb.2025.100261. Acesso em: 12 set. 2026.

MARCONI, Marina de Andrade; LAKATOS, Eva Maria. **Fundamentos de metodologia científica**. 8. ed. São Paulo: Atlas, 2017.

MCKINNEY, Wes. **Python para análise de dados**: tratamento de dados com Pandas, NumPy e Jupyter. 3. ed. São Paulo: Novatec Editora, 2023.

MOREIRA, Vicente et al. Avaliação das barreiras na gestão de estoques do Restaurante Iguarias Cozinha do Mar utilizando o método DEMATEL. **Revista ADMPG**, v. 14, n. 2, 2025. DOI: https://doi.org/10.5212/Admpg.v.01.2503.016. Acesso em: 12 set. 2026.

OECD. OECD ***Framework for the Classification of AI Systems.*** *Paris*: *OECD Publishing*, 2022. DOI: https://doi.org/10.1787/cb6d9eca-en. Acesso em: 16 set. 2026.

OECD. ***Explanatory memorandum on the updated OECD definition of an AI system.*** *Paris: OECD Publishing*, 2024. DOI: https://doi.org/10.1787/623da898-en. Acesso em: 16 set. 2026.

POSCH, Konstantin et al. ***A Bayesian approach for predicting food and beverage sales in staff canteens and restaurants. International Journal of Forecasting***, v. 38, n. 1, p. 321-338, 2022. DOI: https://doi.org/10.1016/j.ijforecast.2021.06.001. Acesso em: 11 set. 2026.

PRESSMAN, Roger S.; MAXIM, Bruce R. **Engenharia de software**: uma abordagem profissional. 9. ed. Porto Alegre: AMGH, 2021.

SANTANA, A. C.; PEREIRA, R.; MATTOS, C. A. Aplicação da *Design Science Research* na elaboração de artefatos digitais. **Revista de Gestão e Tecnologia**, v. 13, n. 2, p. 45-62, 2023.

SCHMIDT, Austin; KABIR, Md Wasi Ul; HOQUE, Md Tamjidul. *Machine Learning Based Restaurant Sales Forecasting*. ***Machine Learning and Knowledge Extraction***, v. 4, n. 1, p. 105-130, 2022. DOI: https://doi.org/10.3390/make4010006. Acesso em: 11 set. 2026.

SERVIÇO BRASILEIRO DE APOIO ÀS MICRO E PEQUENAS EMPRESAS (SEBRAE). **Restaurantes e similares**: emprego e empresas. Observatório Setorial Territorial, [s.d.]. Disponível em: https://observatorio.sebrae.com.br/profile/industry/restaurantes-e-similares. Acesso em: 9 jun. 2026.

SERVIÇO BRASILEIRO DE APOIO ÀS MICRO E PEQUENAS EMPRESAS (SEBRAE). **Sobrevivência das empresas mercantis brasileiras (2020–2024)**: relatório técnico. Brasília: Sebrae, 28 fev. 2025. Disponível em: https://inteligencia.sebraemg.com.br. Acesso em: 9 jun. 2026.

SLACK, Nigel; BRANDON-JONES, Alistair; JOHNSTON, Robert. **Administração da produção**. 8. ed. São Paulo: Atlas, 2018.

SOMMERVILLE, Ian. **Engenharia de software**. 10. ed. São Paulo: Pearson, 2019.

SPOSITO, M. et al. O uso do *Design Science Research* em pesquisas tecnológicas e aplicadas. **Revista Brasileira de Computação Aplicada**, v. 16, n. 1, p. 12-25, 2024.

TABASSI, Elham. ***Artificial intelligence risk management framework (AI RMF 1.0).*** *Gaithersburg: National Institute of Standards and Technology*, 2023. DOI: https://doi.org/10.6028/NIST.AI.100-1. Acesso em: 12 set. 2026.

UNEP. ***Food waste index report 2024.*** *Nairobi*: *United Nations Environment Programme*, 2024.

VIANA, Flavia De Siqueira. Por que ter um restaurante é um negócio tão desafiador? **Comunidade Sebrae**, 14 out. 2024. Disponível em: https://sebraepr.com.br/comunidade/artigo/por-que-ter-um-restaurante-e-um-negocio-tao-desafiador. Acesso em: 9 jun. 2026.

WANKE, Peter. Quadro conceitual para gestão de estoques: enfoque nos itens de baixo consumo. **Gestão & Produção**, São Carlos, v. 19, n. 4, p. 677-687, 2012. DOI: https://doi.org/10.1590/S0104-530X2012000400002. Acesso em: 12 set. 2026.